

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

**Estudo e Concepção de um Sistema de
Monitoramento e Apoio ao Manejo por Visão
Computacional para a Colônia de Gatos da USP São
Carlos**

Felipi Adenildo Soares Sousa

Trabalho de Conclusão de Curso do Programa de Graduação Bacharelado em
Engenharia de Computação

Felipi Adenildo Soares Sousa

Estudo e Concepção de um Sistema de Monitoramento e Apoio ao Manejo por Visão Computacional para a Colônia de Gatos da USP São Carlos

Trabalho de conclusão de curso apresentado ao Programa de Graduação do Instituto de Ciências Matemáticas e de Computação e Escola de Engenharia de São Carlos, Universidade de São Paulo - ICMC - EESC/USP, como parte dos requisitos para obtenção do título de Engenheiro de Computação.

Área de concentração: Engenharia de Computação

Orientador: Prof. Dr. Matheus Machado dos Santos

Versão original

**São Carlos
2026**

*À Zoya, pequena companhia de quatro patas que esteve
ao lado de cada linha deste trabalho e cujo olhar atento
tornou impossível esquecer por que ele importa.*

AGRADECIMENTOS

pendente

*“And God, please let the deer
on the highway
get some kind of heaven.
Something with tall soft grass
and sweet reunion.*

*Let the moths in porch lights
go some place
with a thousand suns,
that taste like sugar
and get swallowed whole.*

*May the mice
in oil and glue
have forever dry, warm fur
and full bellies.*

*If I am killed
for simply living,
let death be kinder
than man.”*

— Althea Davis

RESUMO

Este projeto trata da concepção de um sistema de monitoramento e apoio ao manejo, baseado em visão computacional, para a colônia de gatos comunitários do Campus 2 da Universidade de São Paulo em São Carlos, conduzido em articulação com a atividade de extensão Gatosdoc2. O trabalho parte de um diagnóstico operacional dos dez pontos de observação identificados no campus, sistematiza requisitos de aquisição de imagem (resolução, geometria de captura, autonomia energética, conectividade e armazenamento), e propõe uma arquitetura modular de aquisição assentada em câmeras de *camera trapping* comerciais operando em modo *offline-first*. Sobre essa aquisição, especifica-se um pipeline de visão computacional em quatro fases — triagem por movimento, detecção genérica de fauna, classificação de espécie e reidentificação individual — ancorado em modelos abertos pré-treinados de referência (MegaDetector, SpeciesNet, PetFace e CatFLW). O protocolo experimental adota datasets públicos como condições de contorno representativas do cenário real do Campus 2 (LILA BC, iNaturalist, GBIF, PetFace, CatFLW e WildlifeReID-10k), define baselines mínimos de comparação por fase e consolida instruções operacionais que permitem a reprodução integral do protocolo após a defesa. As contribuições deste projeto situam-se em três planos: técnico (especificação de um pipeline modular sobre modelos abertos), metodológico (protocolo experimental reprodutível) e contextual (vínculo deliberado com a rotina operacional do Gatosdoc2). Trabalhos futuros incluem coleta supervisionada de dados locais, *fine-tuning* dos modelos sobre o catálogo individual da colônia, integração com plataforma de gestão (cadastro, vacinação, castração e adoção responsável) e enriquecimento dos registros com instrumentos automatizáveis de bem-estar animal.

Palavras-chave: visão computacional. *camera trapping*. reidentificação animal. monitoramento de fauna. gatos comunitários. USP São Carlos. extensão universitária.

ABSTRACT

This project addresses the design of a computer-vision-based monitoring and management support system for the community cat colony of Campus 2 of the University of São Paulo at São Carlos, conducted in cooperation with the Gatosdoc2 university extension activity. The work begins with an operational assessment of the ten observation points identified on campus, formalises image-acquisition requirements (resolution, capture geometry, energy autonomy, connectivity and storage), and proposes a modular acquisition architecture grounded on commercial *camera trapping* units operating under an *offline-first* regime. Building on this acquisition, a four-stage computer-vision pipeline is specified — motion-based triage, generic fauna detection, species classification and individual re-identification — anchored on open pre-trained reference models (MegaDetector, SpeciesNet, PetFace and CatFLW). The experimental protocol uses public datasets as boundary conditions representative of the Campus 2 scenario (LILA BC, iNaturalist, GBIF, PetFace, CatFLW and WildlifeReID-10k), defines minimal per-stage comparison baselines and consolidates operational instructions enabling full protocol reproduction after the defence. The contributions of this project fall in three planes: technical (specification of a modular pipeline over open models), methodological (a reproducible experimental protocol), and contextual (deliberate coupling to the operational routine of Gatosdoc2 and the Humanitarian Coexistence Center). Future work includes supervised local data collection, model *fine-tuning* on the colony individual catalogue, integration with a colony management platform (registration, vaccination, neutering and responsible adoption), and enrichment of individual records with automatable animal-welfare instruments.

Keywords: computer vision. *camera trapping*. animal re-identification. wildlife monitoring. community cats. USP São Carlos. university extension.

LISTA DE FIGURAS

Figura 1 – Diagrama de Fluxo de Dados (DFD) arquitetural do pipeline de visão computacional. As quatro fases operam em cascata sobre o acervo bruto consolidado pelo ciclo <i>offline-first</i> : o MegaDetector descarta quadros vazios e dispara o mascaramento da classe “pessoa” antes de qualquer persistência identificável (conformidade com a LGPD, Seção 3.3); o SpeciesNet descarta fauna não-alvo; e o estágio de reidentificação opera apenas sobre quadros confirmados como <i>Felis catus</i> , contra o catálogo de indivíduos da colônia, alimentando os relatórios operacionais da AEX Gatosdoc2.	33
Figura 2 – Curva CMC conceitual da Fase IV (regime <i>closed-set</i>). <i>OBS: traços ilustrativos, a substituir pelas curvas medidas.</i>	51
Figura 3 – Curva conceitual de eficiência do pipeline em cascata em comparação à aplicação ingênua das fases sobre todos os quadros: queda monotônica do volume (eixo <i>y</i> esquerdo, escala logarítmica) contrastada com o custo computacional acumulado (eixo <i>y</i> direito). <i>OBS: traços ilustrativos; substituir pelas curvas empíricas após execução.</i>	53
Figura 4 – Planta georreferenciada dos pontos P01–P10 sobre o mapa institucional do Campus 2 (a produzir).	68

LISTA DE TABELAS

Tabela 1	– Datasets públicos selecionados para a avaliação do pipeline.	44
Tabela 2	– Mapeamento protocolar entre fase, dataset, modelo principal e baseline.	45
Tabela 3	– Desempenho estimado da Fase II por modelo e estrato. <i>OBS: faixas teóricas a substituir após execução.</i>	49
Tabela 4	– Matriz de confusão estimada da Fase III. Linhas: classe verdadeira; colunas: classe predita. <i>OBS: faixas plausíveis com base na literatura recente; substituir pelos valores medidos.</i>	50
Tabela 5	– Desempenho estimado da Fase IV por configuração e regime. <i>OBS: faixas teóricas a substituir após execução do protocolo.</i>	51
Tabela 6	– Funil da cascata na janela sintética de 10 000 quadros. <i>OBS: volumes derivados das taxas de retenção médias das Tabelas 3–5; substituir após execução.</i>	52
Tabela 7	– Síntese comparativa por fase. <i>OBS: Δ aproximado, magnitude qualitativa; substituir após execução real.</i>	53
Tabela 8	– Matriz bruta de infraestrutura dos pontos P01–P10 do Campus 2 da USP São Carlos. Atributos físicos, operacionais e de infraestrutura técnica.	65
Tabela 9	– Coordenadas geográficas aproximadas dos pontos P01–P10, obtidas por GPS de telefone celular. Precisão limitada à do dispositivo; não devem ser tomadas como referência cartográfica oficial.	67

LISTA DE ABREVIATURAS E SIGLAS

AEX	Atividade de Extensão
ABNT	Associação Brasileira de Normas Técnicas
CEUA	Comissão de Ética no Uso de Animais
CSV	<i>Comma-Separated Values</i>
DFD	Diagrama de Fluxo de Dados
ER	Entidade-Relacionamento (modelo de Chen)
FOV	<i>Field of View</i> (campo de visão)
GBIF	<i>Global Biodiversity Information Facility</i>
ICMC	Instituto de Ciências Matemáticas e de Computação
IoU	<i>Intersection over Union</i>
IPCAM	Câmera IP (<i>IP Camera</i>)
JSON	<i>JavaScript Object Notation</i>
LGPD	Lei Geral de Proteção de Dados
LILA BC	<i>Labeled Information Library of Alexandria: Biology and Conservation</i>
mAP	<i>mean Average Precision</i>
NIR	<i>Near-Infrared</i> (infravermelho próximo)
NPU	<i>Neural Processing Unit</i>
PoE	<i>Power over Ethernet</i>
Re-ID	Reidentificação individual (<i>Re-Identification</i>)
SBC	<i>Single-Board Computer</i>
STI	Superintendência de Tecnologia da Informação (USP)
TCC	trabalho de conclusão de curso
USB	<i>Universal Serial Bus</i>
USP	Universidade de São Paulo

USPSC Pacote LaTeX USP São Carlos (classe abntex2)

YAML *YAML Ain't Markup Language*

LISTA DE SÍMBOLOS

mAP	Precisão média (<i>mean Average Precision</i>)
F_1	F-score (média harmônica entre precisão e revocação)
$Rank - k$	Taxa de recuperação ao posto k
τ	Limiar de rejeição em regime <i>open-set</i>
IoU	Intersecção sobre união entre <i>bounding boxes</i>

SUMÁRIO

1	INTRODUÇÃO	15
1.1	Contexto	15
1.2	O problema de engenharia	15
1.3	Objetivos	17
1.4	Justificativa	18
1.5	Organização do trabalho	18
2	AQUISIÇÃO DE IMAGEM EM CAMPO	20
2.1	Pontos de coleta no Campus 2	20
2.2	Requisitos de aquisição	21
2.3	Energia, armazenamento e conectividade	22
2.4	Geometria de captura e proteção	24
2.5	Tipologias de câmera	25
2.6	Arquitetura recomendada	28
3	PIPELINE DE VISÃO COMPUTACIONAL	31
3.1	Arquitetura em quatro fases	31
3.2	Fase I — Ingestão e triagem	34
3.3	Fase II — Detecção generalista	36
3.4	Fase III — Classificação de espécie	38
3.5	Fase IV — Reidentificação individual	39
3.6	Síntese e ponte com a metodologia	41
4	METODOLOGIA EXPERIMENTAL	43
4.1	Objetivos e postura	43
4.2	Datasets públicos	43
4.3	Protocolo por fase	45
4.4	Métricas e regras de reporte	46
4.5	Reprodutibilidade	47
5	RESULTADOS PRELIMINARES E DISCUSSÃO	49
5.1	Posicionamento	49
5.2	Fase II — detecção genérica de fauna	49
5.3	Fase III — triagem de espécie	50
5.4	Fase IV — re-identificação individual	51
5.5	Teste ponta-a-ponta	52

5.6	Discussão integrada	52
6	CONCLUSÃO E TRABALHOS FUTUROS	55
6.1	Síntese	55
6.2	Contribuições	55
6.3	Limitações	56
6.4	Trabalhos futuros	56
	REFERÊNCIAS	58
	APÊNDICES	63
	APÊNDICE A – MATRIZ BRUTA DE INFRAESTRUTURA DOS PONTOS P01–P10	64
	APÊNDICE B – CÓDIGOS	69
B.1	Fase II — detecção	69
B.2	Fase III — classificação	71
B.3	Fase IV — re-identificação	73
B.4	Orquestrador ponta-a-ponta	75
B.5	Consolidação de <i>runs</i>	77

1 INTRODUÇÃO

1.1 Contexto

A presença de gatos de vida livre (*Felis catus*) em campi universitários é fenômeno globalmente documentado e exige respostas técnicas que conciliem bem-estar animal, saúde pública e conservação da fauna nativa. No Brasil, o paradigma técnico-jurídico consolidado para o manejo dessas populações é o protocolo **Captura–Esterilização–Devolução (CED)**, tradução operacional do *Trap–Neuter–Return (TNR)*, cuja eficácia em escala continental e em horizonte de longo prazo é descrita em estudos longitudinais clássicos (Levy; Gale; Gale, 2003; Natoli *et al.*, 2019; Kreisler; Cornell; Levy, 2019) e atualizada em meta-análises recentes (Cecchetti; Nelli, 2025; Schiefer *et al.*, 2025). A literatura é convergente em mostrar que programas TNR de **alta intensidade espacialmente contíguos** reduzem a densidade populacional e a entrada em abrigos, com ganhos consistentes em bem-estar (Gunther *et al.*, 2022; Spehar; Wolf, 2019). Em campus universitário, o estudo de referência é o programa da *University of Central Florida*, que em 28 anos reduziu sua colônia em mais de 85% mantendo apenas TNR e adoção (Spehar; Wolf, 2019), padrão arquitetural reproduzido em diversas universidades latino-americanas (Junqueira; Galera, 2024; Passos; Bovendorp, 2025; Vecchi *et al.*, 2022).

No **Campus 2 da USP São Carlos**, a colônia de aproximadamente 50 gatos distribuídos em 10 pontos de alimentação é manejada pela atividade de extensão **AEX Gatosdoc2**, projeto que reúne docentes, técnicos, discentes e voluntários da comunidade externa. A operação segue os princípios do CED, em conformidade com a **Lei Federal nº 13.426/2017** (BRASIL, 2017), a **Lei Federal nº 15.046/2024** (BRASIL, 2024) e, sobretudo, o **Decreto Federal nº 12.439/2025** (BRASIL, 2025), que institui o Programa Nacional de Proteção e Manejo Populacional Ético de Cães e Gatos e o Cadastro Nacional de Animais Domésticos. A identificação dos animais esterilizados segue a **Resolução CFMV nº 1.595/2024** (CFMV, 2024a), que padronizou o corte reto da ponta da orelha (*ear-tipping*) como marcador visual primário, complementada pelas diretrizes operacionais da **Resolução CFMV nº 1.596/2024** (CFMV, 2024b).

1.2 O problema de engenharia

A operação cotidiana do AEX Gatosdoc2 é hoje sustentada por **vigilância humana presencial**: voluntários realizam visitas regulares aos pontos de alimentação para reposição de ração, observação clínica e tentativa de manter um cadastro atualizado de indivíduos. Esse modelo enfrenta limitações intrínsecas bem documentadas na literatura. Primeiro, a

cobertura temporal é necessariamente esparsa, visitas ocorrem em horários compatíveis com a disponibilidade humana, mas a atividade felina é majoritariamente **crepuscular e noturna** (Cove *et al.*, 2022; Herrera; Cove, 2022). Segundo, a **identificação individual por inspeção visual** é inviável em populações com pelagens parecidas (sólidos pretos, tabbys cinzas, bicolores brancos) e é o gargalo unanimemente apontado em estudos de *capture-recapture* urbano (Cove *et al.*, 2022; Nakashima; Yajima, 2025; Akbar; Rees; Fleming, 2025). Terceiro, a chegada de **novos indivíduos abandonados** — evento crítico no campus, com impacto direto na dispersão da população, depende hoje da percepção subjetiva dos cuidadores, sem registro objetivo do momento ou do ponto de entrada.

O monitoramento sistemático por **armadilhas fotográficas** (*camera trapping*) é a tradição metodológica madura para esse tipo de questão, com trinta anos de literatura em ecologia de fauna (Bruce *et al.*, 2025; Cordier *et al.*, 2022; Swanson *et al.*, 2015; Cove *et al.*, 2022). Câmeras com sensor PIR registram presença sem perturbação humana, permitindo estimar riqueza, ocupação, padrões temporais de atividade e, com identificação individual, densidade populacional. A barreira histórica, porém, é o **volume de imagens**: projetos de escala média geram dezenas a centenas de milhares de capturas que excedem a capacidade humana de classificação (Norouzzadeh *et al.*, 2018; Bruce *et al.*, 2025). A virada do **aprendizado profundo aplicado a camera trapping** resolveu esse gargalo: Norouzzadeh *et al.* (2018) demonstraram automação de 99,3% das classificações do *Snapshot Serengeti* com acurácia equivalente à humana, e o ecossistema atual *MegaDetector + PyTorch-Wildlife* (Hernandez *et al.*, 2024; Microsoft AI for Good, 2026) entrega detecção genérica de animais com licença permissiva e modelos prontos para domínios novos.

A lacuna que motiva este trabalho é específica e atual: **não há, na literatura publicada, sistema integrado de monitoramento por visão computacional voltado a colônias de gatos comunitários em campus universitário brasileiro**, com o trinômio (i) detecção robusta a domínios não vistos, (ii) **re-identificação individual** (re-ID) capaz de operar em *open-set*, isto é, reconhecer indivíduos novos não cadastrados, e (iii) validação humana *no laço* para apoio à decisão dos cuidadores. O trabalho metodologicamente mais próximo é o de Akbar, Rees e Fleming (2025), que aplica re-ID por partes do corpo (face, flanco, cauda) a gatos ferais australianos em vegetação natural; o cenário urbano de campus, com diversidade de pelagem e infraestrutura cooperativa de cuidadores, ainda **não está coberto**.

1.3 Objetivos

Objetivo geral

Estudar e conceber um sistema de monitoramento e apoio ao manejo, baseado em visão computacional, para a colônia de gatos comunitários do Campus 2 da USP São Carlos, integrando captura local de imagens, processamento por modelos pré-treinados com adaptação ao domínio e identificação individual com validação humana, em conformidade com o protocolo CED e com a legislação brasileira vigente.

Objetivos específicos

- O1.** Caracterizar operacionalmente os 10 pontos de alimentação do Campus 2 quanto a energia, conectividade, fluxo de pessoas e fluxo de animais, gerando os requisitos de hardware (Cap. 2).
- O2.** Comparar arquiteturas candidatas de aquisição de imagem — IPCAM, ESP32-CAM e Raspberry Pi com NPU — segundo os critérios de viabilidade, custo total de propriedade e adequação ao campus (Cap. 2).
- O3.** Conceber o **pipeline de visão computacional** em quatro fases (ingestão, detecção, classificação, re-identificação), reutilizando modelos abertos de domínio público (MegaDetector v6, CatFLW, PetFace, WildlifeReID-10k) com adaptação local (Cap. 3).
- O4.** Definir o **protocolo metodológico** de avaliação, com escolha de *datasets* de validação, métricas (mAP, F_1 , Rank- k), e desenho experimental para falhas previsíveis (oclusão, baixa luminosidade, indivíduos novos) (Cap. 4).
- O5. Documentar a continuidade**, entregando matriz de requisitos funcionais, manuais operacionais e roteiros de instalação que permitam a fase de implementação ser executada por outra equipe de engenharia (Cap. 6 e Apêndices A–D).

Trata-se, portanto, de um projeto desta natureza de **estudo e concepção** — a contribuição central é a *arquitetura* do sistema, a justificativa técnica das escolhas e os *artefatos de engenharia* (especificações, diagramas, protocolos, matriz P01–P10) que viabilizam a implementação posterior. *Implementação plena, instalação e validação em campo permanecem como trabalho futuro.*

Nesse contexto, o extenso detalhamento de infraestrutura física e hardware conduzido no Capítulo 2 não visa à entrega de um protótipo físico finalizado (PoC), mas atua estritamente como ferramenta para derivar os parâmetros operacionais e as restrições reais — como variabilidade geométrica, intermitência energética e presença de fauna não-alvo — que a arquitetura de software necessitará suportar.

1.4 Justificativa

A pertinência do trabalho está em três eixos. **(i) Saúde Única:** gatos comunitários estão no centro de questões zoonóticas relevantes no contexto brasileiro — notadamente a esporotricose felina por *Sporothrix brasiliensis*, hoje em expansão epidêmica no sudeste e sul do país (Ferreira *et al.*, 2026; Bastos; Farias, 2025; Colombo; Carvalho *et al.*, 2024), e a toxoplasmose, com seroprevalência documentada em colônias universitárias brasileiras (Kmetiuk *et al.*, 2021; Higa; Araújo *et al.*, 2010). Monitoramento contínuo, sistemático e individualizado é *insumo direto* para vigilância sanitária integrada (Ferroglio *et al.*, 2024) e para a tomada de decisão clínica por médicos veterinários (Santiago; Costa *et al.*, 2025). **(ii) Conservação:** predação por gatos sobre fauna nativa é problema documentado globalmente (Loss; Will; Marra, 2013; Li *et al.*, 2021) e tem revisão específica brasileira recente (Gonçalves; Machado *et al.*, 2025); estimar e mapear pressão de predação no campus exige individualização, o que só a re-ID viabiliza em escala. **(iii) Lacuna técnica brasileira:** enquanto a Europa dispõe da pilha DeepFaune (Rigoudy *et al.*, 2023) e os EUA da plataforma Wildlife Insights/SpeciesNet (Wildlife Insights, 2026; Google Research, 2026), **não existe pilha pública brasileira** de monitoramento por visão computacional para fauna sinantrópica nem, em particular, para gatos comunitários. Este trabalho contribui justamente para fechar essa lacuna, propondo arquitetura aberta e replicável.

A escolha por **reuso de modelos pré-treinados** ao invés de treinamento do zero é fundamentada pela literatura: detectores generalistas treinados em centenas de datasets, como o MegaDetector, generalizam significativamente melhor para regiões geográficas não vistas do que classificadores multi-espécie treinados localmente (Schneider; Taylor; Kremer, 2018; Vélez *et al.*, 2022). O pipeline proposto (detecção genérica → classificação local → re-ID individual) replica o padrão de engenharia recomendado por Mulero-Pázmány *et al.* (2025), que atingiu F_1 de 96,2% sobre 1,3 milhão de imagens em 24 espécies de mamíferos com poucos milhares de exemplos locais. O módulo de re-ID combina o método de Akbar, Rees e Fleming (2025) (*part-based* para gatos ferais) com a verificação face-a-face habilitada pelo dataset **PetFace** (Shinoda; Shiohara, 2024), o maior público para identificação individual em pets, com 257 mil indivíduos. A validação cruzada do sistema usará o benchmark **WildlifeReID-10k** (Adam *et al.*, 2024) como referência externa, alinhada à competição AnimalCLEF (AnimalCLEF, 2026).

1.5 Organização do trabalho

O restante da monografia está organizado em quatro capítulos. O Capítulo 2 trata da **aquisição de imagem em campo**, discutindo em fluxo corrido a caracterização dos 10 pontos do Campus 2, as três famílias de arquiteturas candidatas, energia e conectividade,

e a decisão arquitetural recomendada. O Capítulo 3 descreve em quatro fases, ingestão, detecção, classificação e re-identificação, como os dados brutos das câmeras são transformados em registros individuais auditáveis, com fundamentação em modelos abertos. O Capítulo 4 detalha datasets de validação, métricas, desenho experimental e tratamento de falhas previsíveis. O Capítulo 6 consolida as contribuições, discute condições de contorno e indica trabalhos futuros, com ênfase em continuidade operacional.

Os **Apêndices** reúnem os artefatos de engenharia produzidos pelo autor: a matriz P01–P10 dos pontos de alimentação (Apêndice A) e os códigos do pipeline (Apêndice B). Os demais artefatos operacionais — requisitos funcionais, manuais e *datasheets* de referência — são mantidos como documentação de execução no repositório do projeto, fora desta monografia.

2 AQUISIÇÃO DE IMAGEM EM CAMPO

2.1 Pontos de coleta no Campus 2

A discussão de hardware parte dos dez pontos de alimentação efetivamente operados no Campus 2 da USP São Carlos, não de um cenário idealizado. O levantamento foi conduzido em campo por inspeções cooperativas junto aos voluntários da atividade de extensão AEX Gatosdoc2, combinando ficha técnica, registro fotográfico georreferenciado e observação direta da rotina de alimentação — procedimento alinhado às práticas de *camera trapping* cooperativo, em que o conhecimento operacional dos cuidadores é informação primária (Vélez *et al.*, 2022; Cordier *et al.*, 2022). A matriz consolidada P01–P10 (Apêndice A) reúne os atributos de campo; aqui são sintetizados apenas aqueles que condicionam o problema de software do Capítulo 3.

Três eixos delimitam esse problema. O primeiro é *físico*: os abrigos são estruturas adaptadas pelos voluntários — as “casas de reciclagem” construídas com caixas plásticas, telhas de fibrocimento, madeira recuperada e potes domésticos —, dispostas no solo com geometria, altura e orientação variáveis. Trata-se, portanto, de infraestrutura não padronizada sobre a qual o módulo de captura deve ser retrofitável, sem obra civil e com baixo impacto visual. O segundo é *energético e comunicacional*: sete dos dez pontos não dispõem de qualquer tomada de corrente alternada em raio operacionalmente útil (≈ 20 m), o que torna inviável alimentação por rede elétrica como solução abrangente; em contrapartida, nove pontos recebem mais de quatro horas de incidência solar direta por dia (a exceção é o ponto P05, em corredor coberto). Wi-Fi USP e 4G alcançam nominalmente todos os pontos, mas a literatura adverte que disponibilidade nominal não equivale a estabilidade sustentada em ambiente externo arborizado (Bruce *et al.*, 2025; Vélez *et al.*, 2022), ressalva que motivará a opção por arquitetura *offline-first*.

O terceiro eixo é *ecológico* e tem consequência algorítmica direta. Por estarem dispostos no solo, os potes atraem rotineiramente fauna não-alvo recorrente: gambás (*Didelphis albiventris*), quatis (*Nasua nasua*), lagartos teiú, pombos, aves nativas e, criticamente, felinos silvestres como o gato-mourisco (*Herpailurus yagouaroundi*), cuja presença em fragmentos urbanos da região central do estado de São Paulo é documentada em revisões recentes de fauna sinantrópica (Gonçalves; Machado *et al.*, 2025; Cove *et al.*, 2022). Essa biodiversidade altera o problema de software: não basta detectar presença diante do pote — é preciso **discriminar a espécie** antes de submeter o quadro às etapas seguintes. A justificativa para o emprego de modelos generalistas como o SpeciesNet (Google Research, 2026) e a pilha MegaDetector + PyTorch-Wildlife (Hernandez *et al.*, 2024; Microsoft AI for Good, 2026) deriva diretamente dessa observação: filtrar o ruído biológico antes da

reidentificação é condição necessária para que a re-ID de *Felis catus* opere com taxas de falso positivo aceitáveis.

A leitura conjunta dos três eixos delimita o problema tratado no restante do capítulo: dimensionar uma infraestrutura de aquisição autônoma em energia na maioria dos pontos, tolerante a falhas de conectividade, capaz de operar em condições crepusculares e noturnas, discreta o suficiente para integrar-se às casinhas existentes e retrofitável sem alterar a infraestrutura física. Essas restrições definem os desafios que o pipeline do Capítulo 3 absorverá como parâmetros de entrada: variabilidade geométrica, iluminação heterogênea, intermitência de captura, presença sistemática de classes não-alvo e impossibilidade de pressupor canal de transmissão confiável.

Portanto, o hardware é tratado aqui como o contexto delimitador do problema; a análise dessas restrições físicas fornece os requisitos de entrada rigorosos para o pipeline de visão computacional, que constitui a verdadeira entrega de engenharia deste trabalho.

2.2 Requisitos de aquisição

A definição do hardware de captura é tratada como problema de análise de viabilidade. As restrições mapeadas na Seção 2.1 são traduzidas em pré-requisitos que delimitam o espaço de soluções aceitáveis, separando os **mínimos** — sem os quais o pipeline do Capítulo 3 é inviável — dos **desejáveis**, que diferenciam uma solução adequada à escala e à rotina da AEX Gatosdoc2. A confrontação desses requisitos com as tipologias arquiteturais disponíveis é objeto da Seção 2.5.

Os *requisitos mínimos* delimitam o que a infraestrutura precisa entregar para que o pipeline seja tecnicamente viável. O primeiro é o **acionamento autônomo por movimento**, realizável por duas vias funcionalmente análogas mas energeticamente distintas: por *hardware*, com sensor infravermelho passivo (PIR) que mantém o subsistema principal em sono profundo até variação térmica no campo de visão; ou por *software*, com câmera permanentemente ativa que dispara gravação ao detectar variação significativa de pixels entre quadros sucessivos. A literatura é convergente quanto à necessidade de algum mecanismo de disparo: *ghost frames* acionados por vento, sombra ou variação térmica espúria respondem por metade ou mais do volume bruto capturado, e a gravação contínua é inviável em escala plurianual (Bruce *et al.*, 2025; Vélez *et al.*, 2022; Swanson *et al.*, 2015). A taxa de *ghost frames* efetivamente entregue é parâmetro que o filtro de pré-processamento do pipeline precisará dimensionar.

Compõem ainda os mínimos a **vedação ambiental** (classe IP66 ou superior, Seção 2.4), a **autonomia energética** compatível com pontos sem corrente alternada (Seção 2.3), o **armazenamento local** suficiente para o regime *offline-first* entre ciclos de coleta e a **captura noturna por infravermelho próximo** (NIR), sem a qual mais de metade dos pontos perderia a janela crepuscular e noturna em que parte significativa da atividade da

colônia ocorre. Cada um desses requisitos restringe não apenas o que o módulo precisa ser, mas o regime de qualidade de imagem com que o pipeline terá de operar.

Aos mínimos somam-se *requisitos desejáveis*, que traduzem o diferencial de engenharia do projeto. O primeiro é a **capacidade de processamento na borda** (*Edge AI*): inferências leves que descartam quadros sem animal, filtram vegetação em movimento e rejeitam fauna não-alvo antes da transmissão, desonerando o canal de comunicação, reduzindo armazenamento na nuvem e encurtando a malha de validação humana, conforme reportado em implantações recentes (Velasco-Montero *et al.*, 2024; Pishdast; Kalva; Tye, 2025; Mulero-Pázmány *et al.*, 2025). O segundo é a **conectividade nativa** para sincronização opcionalmente intermitente, que dispensa coleta manual sistemática de cartões e habilita o protocolo de validação humana no laço. Esses dois requisitos não condicionam a existência do sistema, mas determinam o quanto do pipeline pode ser deslocado para a borda em vez de operar inteiramente em servidor.

2.3 Energia, armazenamento e conectividade

Energia disponível e canal de saída dos dados são, no Campus 2, condições materiais que precedem qualquer escolha algorítmica. A Seção 2.1 já evidenciou a assimetria estrutural dos dez pontos: apenas três dispõem de tomada regular, a maioria está exposta a longa insolação direta, e a rede sem fio institucional está nominalmente disponível, mas operacionalmente sujeita a autorizações e janelas de manutenção fora do alcance do projeto. Essas condições orientam o subsistema para o regime *offline-first*, em que a continuidade da aquisição não depende de rede e a sincronização é tratada como camada opcional. Para o pipeline do Capítulo 3, isso implica projeto predominantemente em **lote**, sobre quadros consolidados em servidor após ciclos de coleta.

A discussão energética articula três regimes. Nos pontos com tomada elétrica, câmeras IP comerciais modificadas para operação local e SBC com NPU operam confortavelmente em ciclo contínuo, com folga para iluminação ativa por NIR e janelas de inferência prolongadas, salvo riscos pontuais de queda de tensão amortecidos por fontes estabilizadas. Esse regime define o teto operacional a partir do qual as etapas mais exigentes do pipeline podem migrar para a borda, mas alcança parcela minoritária dos pontos. O regime majoritário é o de **alimentação fotovoltaica**: SBCs de classe Raspberry com aceleradores neurais dissipam potência não desprezível em operação contínua, exigindo painel, controlador de carga e banco de bateria dimensionados com folga para o ciclo diário e reserva para dias nublados consecutivos — requisito já reportado como dimensionante em sistemas similares (Velasco-Montero *et al.*, 2024; Pishdast; Kalva; Tye, 2025; Sargent *et al.*, 2021). A iluminação ativa por NIR é item energético sensível: emissores potentes resolvem o problema óptico noturno mas inflacionam o consumo médio, deslocando o ponto de operação para fora do envelope viável de painéis e baterias razoáveis. Por esse motivo,

reduzir o nível de processamento do SBC para o ESP32-CAM, ou aceitar perda parcial de cobertura noturna, é alternativa legítima em vez de regressão técnica; plataformas embarcadas mais leves oferecem flexibilidade adicional (Tiddeman *et al.*, 2023). O terceiro regime, das câmeras alimentadas por **baterias** (*trail cam* comercial, Seção 2.5), opera com consumo médio próximo de zero pela combinação de PIR físico e *deep sleep*, ao custo de processamento de borda essencialmente nulo e de cadência de troca ou recarga das baterias incorporada ao protocolo de campo. Consequentemente, o pipeline não pode pressupor processamento de borda uniforme: a divisão borda-servidor varia com o orçamento energético local, e o software deve tolerar essa heterogeneidade.

O armazenamento local, no regime *offline-first*, é canal primário de persistência. Cartões *microSD* de classe industrial, com tolerância térmica ampliada e algoritmos robustos de *wear leveling*, são o suporte usual; cartões de consumo têm histórico documentado de falha precoce sob ciclos intensos de escrita e variação térmica externa (Tiddeman *et al.*, 2023; Sargent *et al.*, 2021). A política de gravação equilibra densidade de informação retida (taxa de quadros, resolução, metadados de inferência) e envelhecimento do meio físico, com rotação programada e marcação de blocos consolidados, definindo a taxa de chegada de dados e o horizonte temporal das análises de re-ID. Operacionalmente, o ciclo logístico é independente de rede: cartões são retirados em campo pelos cuidadores ou pela equipe técnica e transferidos ao servidor (Seção 2.6), com cadência semanal ou quinzenal compatível com a rotina da AEX Gatosdoc2. A queda de tensão durante escrita em curso é mitigada por sistemas de arquivos com *journaling* e escrita em blocos atômicos com renomeação final (Sargent *et al.*, 2021).

A conectividade, ao contrário de energia e armazenamento, é variável institucional. A rede sem fio da Universidade está nominalmente disponível, mas seu uso por dispositivos embarcados depende de autorização da Superintendência de Tecnologia da Informação, credenciais compatíveis com autenticação corporativa (tipicamente *802.1X EAP-PEAP*) e configuração consistente em cada nó — tarefas que se aproximam mais da escala de complexidade burocrática do que da técnica. A rede celular *4G/LTE* opera sob lógica análoga: tecnicamente trivial, institucionalmente custosa. A consequência metodológica é tratar conectividade como camada opcional adicionada sobre um sistema já completo em modo *offline-first*. Quando autorizada, habilita sincronização oportunista, supervisão remota e atualização de modelos em borda; quando indisponível, o sistema continua a operar com cadência de análise atrelada ao ciclo logístico. Nenhuma funcionalidade central do pipeline pode depender de conectividade ininterrupta: validação humana no laço, atualização de modelos e sincronização de resultados são camadas adicionais, não pré-requisitos.

2.4 Geometria de captura e proteção

Qualquer que seja a tipologia escolhida na Seção 2.5, o módulo de aquisição deve sobreviver fisicamente ao ambiente do Campus 2 e produzir quadros cujas *features* visuais sejam efetivamente utilizáveis pelas etapas seguintes. Esta seção trata das duas dimensões físicas transversais a essas tipologias — acondicionamento dos componentes e geometria de captura junto aos abrigos — no plano da análise de viabilidade.

A primeira preocupação de acondicionamento é **ambiental**. Os pontos P01–P10 estão expostos a chuva, orvalho, poeira, variação térmica diária acima de 15 °C e, em vários casos, contato direto com vegetação e solo úmido. Invólucros classe **IP66** (proteção total contra poeira e jatos d’água) ou **IP67** (imersão temporária) são requisito não negociável. Em paralelo, surge o *trade-off* clássico entre vedação e ventilação: módulos com SBC e NPU dissipam calor não desprezível em operação contínua, e invólucros completamente vedados podem elevar a temperatura interna a ponto de comprometer a estabilidade dos sensores, problema reportado em sistemas semelhantes operados em climas tropicais (Tiddeman *et al.*, 2023; Sargent *et al.*, 2021). Essa restrição impacta o regime térmico do sensor de imagem, com possíveis consequências sobre ruído, faixa dinâmica e estabilidade colorimétrica dos quadros entregues ao pipeline.

A segunda preocupação é **patrimonial e cooperativa**. *Camera trapping* é, internacionalmente, campo afetado por furto e vandalismo: levantamentos com centenas de profissionais documentam perdas anuais expressivas e indicam que as estratégias mais efetivas combinam camuflagem visual, fixação robusta e posicionamento que reduza a saliência do equipamento (Meek *et al.*, 2019). No Campus 2, o sistema será instalado em ambiente comunitário cooperativo, compartilhado por estudantes, técnicos, voluntários e visitantes externos. Câmeras visivelmente identificáveis tendem a alterar tanto o comportamento de pessoas quanto, em alguma medida, a frequência dos abrigos pelos próprios gatos — componente comportamental relevante em estudos urbanos de fauna sinantrópica (Cove *et al.*, 2022). A diretriz é, portanto, integrar o módulo às “casinhas de reciclagem” existentes, aproveitando seu volume para abrigar a caixa eletrônica. Para o pipeline, isso implica que a posição do sensor é dada pelo abrigo, convertendo-se em parâmetro fixo de calibração geométrica por ponto.

A geometria com que a câmera observa o ponto precede qualquer escolha de modelo, pois determina o que é geometricamente possível extrair do quadro. Para o pipeline aqui projetado, dois conjuntos de *features* precisam ser preservados em fração estatisticamente significativa dos quadros: a **face** do animal (relevante para abordagens face-a-face habilitadas pelo PetFace) e o **flanco**, incluindo padrão de pelagem, contorno corporal e marcação de orelha (*ear-tipping*), conforme o método de re-ID por partes do corpo de Akbar, Rees e Fleming (2025). Posicionamentos que registrem o animal apenas pelo dorso ou exclusivamente em silhueta contraluz comprometem a reidentificação antes mesmo da escolha do modelo, transferindo ao pipeline um problema geometricamente insolúvel.

A literatura fornece direção qualitativa robusta. Para mamíferos de pequeno e médio porte, à altura típica dos gatos comunitários, alturas baixas (algumas dezenas de centímetros, próximas ao nível dos ombros do animal) maximizam taxa de detecção e qualidade da identificação individual, ao passo que posicionamentos elevados, frequentemente adotados como medida antifurto, reduzem significativamente tanto a probabilidade de disparo quanto a utilidade dos quadros para classificação fina (Seidlitz *et al.*, 2020; Beukes *et al.*, 2025; Meek; Ballard; Falzon, 2016). No plano angular, ângulos levemente picados, com linha de visada apontada para o entorno imediato dos potes, oferecem o melhor compromisso entre cobertura do cone útil, captura simultânea de face e flanco e minimização de obstrução por vegetação rasteira (Beukes *et al.*, 2025; Moll *et al.*, 2020). A obstrução do cone de visão por vegetação no primeiro plano reduz substancialmente a taxa efetiva de detecção — queda da ordem de duas a três vezes em sítios visualmente carregados (Moll *et al.*, 2020) —, diretriz que se traduz, no Campus 2, em remoção periódica de folhagem incorporada à rotina dos cuidadores. A iluminação ativa por NIR precisa estar coalinhada com o eixo óptico e dimensionada para o alcance típico do ponto, sob pena de gerar quadros saturados próximos ao módulo e escuros para além de distância curta. Essas restrições geométricas e fotométricas são parâmetros de entrada do pipeline do Capítulo 3: o que o software pode extrair sobre indivíduos da colônia está limitado, em última instância, pela qualidade angular, espacial e fotométrica dos quadros que a infraestrutura entrega.

2.5 Tipologias de câmera

Consolidados o conjunto de requisitos (Seção 2.2) e as condições de contorno físicas (Seção 2.4) e energéticas (Seção 2.3), torna-se possível percorrer comparativamente as quatro tipologias arquiteturais hoje disponíveis para aquisição autônoma em campo. A discussão é organizada como *escada tecnológica* ordenada por compatibilidade crescente com os requisitos desejáveis. A leitura não é hierárquica no sentido econômico: cada degrau resolve parte do problema e introduz novos *trade-offs*. A escolha consolidada para o Campus 2, articulada na Seção 2.6, fixa um único degrau como tipologia operacional e reserva os demais a finalidades experimentais e de evolução futura.

Câmeras IP comerciais domésticas.

O primeiro degrau é o de maior acessibilidade: o reaproveitamento de **câmeras IP de consumo** (IPCAMs), originalmente projetadas para vigilância residencial com energia elétrica contínua e Wi-Fi estável, adaptadas para operação autônoma. Essa adaptação envolve três intervenções complementares. A primeira é a substituição da alimentação de rede por bancos de bateria recarregável (*powerbanks*) dimensionados para múltiplos dias de operação, com gravação local em cartão SD industrial em substituição ao armazenamento

em nuvem do fabricante. A segunda é a modificação do *firmware*: muitas IPCAMs são distribuições Linux embarcadas (kernel customizado sobre *BusyBox*) cujo acesso, por interfaces de *debug* ou *firmware* alternativo, permite desabilitar rádios não utilizados (Wi-Fi, Bluetooth), suprimir serviços de telemetria e ajustar a política de gerenciamento de energia ao caso de uso real. Iniciativas comunitárias de *firmware* aberto — com destaque para o projeto **OpenIPC**, voltado a câmeras IP com SoCs HiSilicon, Xiongmai, SigmaStar, GoKe e Ingenic — têm tornado tecnicamente acessível a troca do *firmware* de fábrica por imagens enxutas, auditáveis e configuráveis ([OpenIPC Project, 2025](#)), ao custo de compatibilidade verificada modelo a modelo. A terceira intervenção é a integração mecânica ao abrigo, conforme a Seção 2.4. A objeção crítica a esse degrau está ligada ao primeiro requisito mínimo: quando a detecção de movimento é implementada por *software*, o subsistema de imagem precisa permanecer permanentemente ativo, drenando rapidamente a bateria mesmo sem captura efetiva. Modelos com sensor PIR de *hardware* nativo amenizam o problema, mas o consumo em modo ocioso permanece superior ao de arquiteturas projetadas para operação autônoma desde a origem ([Velasco-Montero et al., 2024](#)). Para o pipeline do Capítulo 3, esse degrau implica receber quadros vindos de um codec proprietário, com pouca margem para metadados de inferência embarcada e taxa de *ghost frames* potencialmente elevada quando o disparo é puramente por software.

Câmeras de trilha (*trail cameras*).

O segundo degrau resolve o ponto fraco anterior por desenho. As *trail cameras*, herdeiras de três décadas de tradição em ecologia de fauna ([Bruce et al., 2025](#); [Cordier et al., 2022](#); [Swanson et al., 2015](#)), são equipamentos integrados que reúnem nativamente sensor PIR de hardware, vedação ambiental classe IP66 ou IP67, iluminação infravermelha próxima embarcada e autonomia superior a meses de operação com baterias alcalinas ou de lítio. Esses atributos as posicionam, em robustez mecânica e autonomia energética, como referência do segmento. O custo dessa maturidade é a **arquitetura fechada**: o *firmware* é proprietário e não admite injeção de algoritmos customizados na borda; o pipeline de imagens é encerrado no ciclo gravação → cartão SD → coleta manual; e mesmo modelos com transmissão 4G nativa operam sob protocolos e nuvens proprietárias, dificultando a integração ao restante da arquitetura. A *trail camera* cumpre todos os requisitos mínimos mas falha sistematicamente nos desejáveis: não há *Edge AI* possível e a sincronização, quando existe, é cativa. Consequentemente, nenhuma etapa do pipeline do Capítulo 3 pode ser deslocada para a borda, e todas as decisões de detecção, classificação e re-ID precisam ocorrer a posteriori em servidor.

Microcontroladores com câmera embarcada (ESP32-CAM e similares).

O terceiro degrau é o do *hardware* aberto. Plataformas como o ESP32-CAM reúnem custo unitário irrisório, consumo extremamente baixo em modo ocioso, suporte nativo a PIR de *hardware* por GPIO, comunicação Wi-Fi e gravação em cartão SD em um único módulo. São tipicamente utilizadas em prototipagem, em redes densas de baixo custo e em pontos onde a perda do equipamento é aceitável (Velasco-Montero *et al.*, 2024). O *trade-off* é duplo: a qualidade ótica do sensor embarcado é marginal para tarefas exigentes como a reidentificação individual (iluminação, foco e faixa dinâmica insuficientes para os padrões finos de pelagem) e a capacidade computacional do microcontrolador, ainda que admita modelos diminutos via TinyML, é insuficiente para hospedar detectores generalistas como o MegaDetector. O módulo opera, portanto, essencialmente como conduto de imagens, adequado a tarefas binárias de presença e a prototipagem, mas inadequado como solução final em um sistema cuja finalidade é a reidentificação individual em ambiente urbano. Para o pipeline, esse degrau não modifica a divisão borda-servidor frente à *trail camera* e adiciona limitação de qualidade ótica de entrada que se tornaria fator restritivo da própria etapa de re-ID.

Computadores em placa única com aceleradores neurais (SBC + NPU).

O quarto degrau é o paradigma mais alinhado aos requisitos desejáveis. Computadores em placa única (*Single Board Computers*, SBC), como o Raspberry Pi, são empregados há mais de uma década em monitoramento ecológico de baixo custo, com casos documentados em ninhos de aves, comportamentos crípticos de pequenos vertebrados e ambientes hostis (Sargent *et al.*, 2021). Sem aceleração neural dedicada, contudo, esses sistemas operam no limite do orçamento computacional, com latência e consumo incompatíveis com inferência contínua (Tiddeman *et al.*, 2023). A combinação do SBC com uma **Unidade de Processamento Neural** (NPU) — a exemplo do Google Coral Edge TPU ou do Hailo-8 — altera essa equação: torna-se possível executar localmente detectores generalistas como o MegaDetector e classificadores multi-espécie como o SpeciesNet, transmitindo apenas metadados estruturados ou quadros previamente filtrados (Pishdast; Kalva; Tye, 2025; Velasco-Montero *et al.*, 2024; Mulero-Pázmány *et al.*, 2025). O preço é um custo unitário significativamente superior e dimensionamento energético mais robusto, com painéis solares e bancos de bateria adequadamente especificados conforme a Seção 2.3. Para o pipeline, este é o único degrau que efetivamente habilita uma divisão de trabalho borda-servidor: detecção e classificação multi-espécie podem ocorrer no campo, descartando o ruído biológico antes da transmissão, e somente quadros pré-filtrados chegam ao servidor para reidentificação individual.

A leitura conjunta dos quatro degraus prepara a Seção 2.6: nenhuma das tipologias satisfaz simultaneamente todos os requisitos mínimos e desejáveis sob o orçamento típico de

um projeto de graduação operado em ambiente cooperativo, e a escolha operacional resulta de compromisso entre custo, disponibilidade no comércio nacional, simplicidade de manejo e controle do nó de campo. As câmeras IP comerciais adaptadas, em particular sob *firmware* aberto, oferecem o melhor desse compromisso para os dez pontos do Campus 2; as *trail cameras* permanecem como referência para validação experimental em condições severas de energia; o SBC com NPU mantém-se como horizonte aspiracional para evoluções futuras com processamento de borda; e os microcontroladores ficam restritos a prototipagem ou a redes densas com finalidade exploratória. A Seção 2.6 articula essa síntese em uma decisão arquitetural concreta para o Campus 2.

2.6 Arquitetura recomendada

As cinco seções anteriores estabeleceram o problema material em camadas: dez pontos com geometria não padronizada, sete sem tomada elétrica e nove com insolação direta suficiente para alimentação fotovoltaica (Seção 2.1); requisitos mínimos e desejáveis confrontados com a realidade operacional (Seção 2.2); conjunto de restrições de invólucro e geometria de captura (Seção 2.4); regime *offline-first* como princípio energético e comunicacional (Seção 2.3); e quatro tipologias arquiteturais hoje disponíveis, com seus respectivos *trade-offs* (Seção 2.5). Esta seção articula essas camadas em decisão arquitetural concreta para o Campus 2 e fixa o quadro de parâmetros que o pipeline do Capítulo 3 recebe como entrada.

Síntese das restrições

A leitura cruzada das seções anteriores mostra que o projeto opera em envelope estreito definido por seis vetores: heterogeneidade material entre pontos; escassez de tomadas em sete dos dez pontos, contrabalançada pela alta viabilidade solar em nove deles; instabilidade institucional da conectividade, que rebaixa a rede à condição de camada opcional e impõe *offline-first* como princípio; biodiversidade não-alvo recorrente, que inviabiliza soluções baseadas apenas em detecção genérica de movimento e exige classificação multi-espécie; regime de baixa luminosidade noturna, que torna a iluminação por infravermelho próximo simultaneamente requisito funcional e item energético sensível; e contexto cooperativo da AEX Gatosdoc2, que recomenda baixa saliência visual do equipamento e integração às casinhas de reciclagem existentes. Esses seis vetores são as condições de contorno sob as quais qualquer aquisição é possível, e o pipeline do Capítulo 3 terá de aceitá-las como dadas.

Decisão arquitetural: tipologia única padronizada

Em princípio, a heterogeneidade entre pontos abriria espaço para um *arranjo arquitetural heterogêneo*, com tipologia escolhida ponto a ponto a partir do envelope material local. Essa opção, embora tecnicamente defensável, é incompatível com a escala operacional do projeto: um arranjo com quatro tipologias distintas exigiria quatro cadeias logísticas paralelas de aquisição, peça de reposição, treinamento, configuração e manutenção, em sistema mantido por equipe enxuta de voluntários sem dedicação técnica integral. A consequência prática é **a adoção de tipologia única padronizada para os dez pontos**, mesmo a custo de algum subaproveitamento de envelope em pontos com folga energética. A padronização viabiliza estoque rotativo de unidades equivalentes, substituição célere em caso de falha, procedimento único de configuração e treinamento mínimo da equipe de campo, alinhando a decisão arquitetural ao perfil de operação cooperativa documentado na Seção 2.1.

Confrontados orçamento típico de projeto de graduação, disponibilidade no comércio nacional e opinião dos voluntários quanto à facilidade de manejo, a tipologia escolhida é a **câmera IP comercial doméstica adaptada, com gravação local em cartão microSD industrial, operação estritamente *offline* e alimentação por *powerbank*** (Seção 2.5, primeiro degrau). Quatro argumentos sustentam essa decisão. O primeiro é o **custo unitário**: câmeras IP de consumo doméstico são significativamente mais baratas que *trail cameras* de média gama e que conjuntos SBC+NPU completos, o que viabiliza a cobertura simultânea dos dez pontos sob o orçamento disponível, com reserva para unidades de estoque rotativo. O segundo é a **disponibilidade no comércio nacional**: hardware, peças de reposição, fontes, *powerbanks*, cartões microSD industriais e suportes mecânicos são facilmente encontrados, o que reduz o risco logístico e o tempo médio de recuperação de falhas em campo. O terceiro é a **simplicidade operacional para os voluntários**: o ciclo de campo se reduz à troca do *powerbank* e à retirada periódica do cartão microSD, sem necessidade de painel fotovoltaico, controlador de carga ou rede sem fio dedicada por ponto — procedimento já compatível com a rotina de alimentação semanal da colônia. O quarto é o **controle do nó de campo**: a substituição do *firmware* de fábrica por uma imagem baseada no projeto OpenIPC ([OpenIPC Project, 2025](#)), quando o SoC suportar, permite operar em regime estritamente local, desabilitar rádios não utilizados, conter o consumo em modo ocioso e expor interface administrativa auditável, mitigando simultaneamente as fragilidades energética, de privacidade e de dependência de fornecedor associadas ao uso da câmera sem modificação.

Alternativas reservadas a testes e evoluções futuras

A escolha por tipologia única não exclui as demais tipologias da escada tecnológica; reserva-as a finalidades específicas no horizonte de evolução do projeto. As *trail cameras*

alimentadas por baterias permanecem como referência comparativa para validação experimental nos pontos sem insolação adequada e em ciclos de campo nos quais se queira contrastar a taxa de *ghost frames* e a qualidade noturna entre tipologias. Conjuntos SBC com NPU mantêm-se como referência aspiracional para etapas do pipeline em borda, podendo ser implantados em uma ou duas unidades-piloto para avaliar o ganho de descarte antecipado de quadros sem animal e de classificação multi-espécie embarcada, em preparação a futuras versões do sistema que exijam operação próxima ao tempo real. Os módulos baseados em microcontrolador (ESP32-CAM e similares) ficam reservados a redes densas de prova de conceito ou a pontos cuja perda do equipamento por vandalismo seja considerada aceitável. Em todos os casos, essas tipologias entram no projeto como **unidades experimentais paralelas**, não substituindo a tipologia padronizada nos dez pontos operacionais; sua função é fornecer evidência empírica para eventual migração arquitetural em versões futuras do sistema.

Consequências para o pipeline

A adoção de câmeras IP comerciais em modo *offline* como tipologia única tem três consequências metodológicas diretas para o Capítulo 3. Em primeiro lugar, o pipeline pode pressupor, como caso de uso operacional, a chegada de quadros em formato comprimido (JPEG ou H.264) a partir de câmeras IP em modo *offline*, sem metadados de pré-inferência embarcada, devendo concentrar capacidade de processamento integral em servidor. Em segundo lugar, a uniformidade da tipologia simplifica o estágio de normalização e calibração, que passa a tratar variações de geometria e iluminação entre pontos sem precisar absorver heterogeneidade adicional vinda do próprio sensor. Em terceiro lugar, a cadência de chegada de dados é determinada pelo ciclo logístico de retirada de cartões e troca de *powerbanks* pelos voluntários, com periodicidade semanal ou quinzenal, o que estrutura o pipeline em regime de **lote** sobre janelas históricas e dispensa hipóteses sobre latência de transmissão. A presença sistemática de fauna não-alvo, herdada da Seção 2.1, mantém a classificação multi-espécie como pré-requisito funcional da re-ID, agora aplicada a um regime visual de entrada uniforme entre pontos.

A discussão acima manteve-se no plano qualitativo. Os atributos de campo consolidados por ponto (energia, conectividade, incidência solar, fauna não-alvo, risco de vandalismo, entre outros) são reunidos na matriz P01–P10 do Apêndice A, que serve como evidência de engenharia da decisão arquitetural aqui sintetizada. O detalhamento numérico do dimensionamento de *powerbanks* e cartões microSD, das classes IP, dos ângulos de montagem e dos *datasheets*, fora do foco deste trabalho centrado no software de visão computacional, é parte do projeto executivo subsequente.

3 PIPELINE DE VISÃO COMPUTACIONAL

3.1 Arquitetura em quatro fases

Consolidado o quadro de aquisição no Capítulo 2 — tipologia única padronizada com câmeras IP comerciais adaptadas, gravação local em cartão microSD industrial, operação *offline* e alimentação por *powerbank* —, o problema central do trabalho deixa de ser “capturar o quadro” e passa a ser “extrair do quadro a informação útil ao manejo da colônia”. Esta etapa concentra a contribuição de engenharia de software e de visão computacional do projeto. O pipeline aqui descrito absorve como parâmetros de entrada a posição fixa do sensor por abrigo, a presença sistemática de fauna não-alvo no Campus 2, a ausência de canal de transmissão contínuo e a cadência de chegada de dados ditada pelo ciclo logístico de retirada de cartões pelos voluntários da AEX Gatosdoc2.

Forma de chegada dos dados

A tipologia padronizada definida na Seção 2.6 fixa a forma de chegada dos dados ao pipeline. Cada um dos dez pontos entrega vídeo comprimido em padrões *H.264* ou *H.265* gravado no cartão microSD da IPCAM, retirado periodicamente em campo e transferido para um diretório de trabalho do servidor, organizado por ponto e por janela de coleta. A homogeneidade da entrada é consequência direta da decisão arquitetural anterior e simplifica o tratamento na Fase I, que passa a operar sobre um único formato canônico em vez de absorver heterogeneidade de sensores diferentes. Eventuais unidades experimentais paralelas reservadas a testes (*trail cameras*, SBC+NPU, ESP32-CAM, Seção 2.6) produzem mídia em formatos distintos (*JPEG* estático, vídeo proprietário, sequências numeradas), tratada por adaptadores dedicados de ingestão sem alterar a lógica das fases subsequentes. Em todos os casos a ingestão se dá por **retirada física dos cartões**, e não por *streaming* contínuo, o que faz com que o pipeline opere em **regime de lote** sobre janelas históricas de mídia.

Justificativa das quatro fases

A partir desse ponto, o pipeline se organiza em quatro fases sequenciais cuja ordem é ditada pela natureza do problema, não por uma arquitetura genérica de visão computacional. A **Fase I** (Seção 3.2) realiza a *ingestão e o pré-tratamento* das mídias, convertendo vídeo H.264/H.265 em um conjunto canônico de quadros prontos para inferência, com extração a baixa taxa, normalização leve e anexação de metadados de proveniência por ponto. A **Fase II** (Seção 3.3) executa a *detecção generalista de animais*, descartando o volume

amplamente majoritário de *ghost frames* e quadros vazios antes que qualquer custo computacional adicional seja incorrido — estratégia consolidada na literatura de *camera trapping* em larga escala (Bruce *et al.*, 2025; Velasco-Montero *et al.*, 2024; Mulero-Pázmány *et al.*, 2025). A **Fase III** (Seção 3.4) é especialmente pertinente ao caso do Campus 2: a presença sistemática de fauna não-alvo discutida na Seção 2.1 torna obrigatória uma etapa de *classificação multi-espécie* que filtre gambás, quatis, aves, lagartos e felinos silvestres antes do estágio seguinte. Somente os quadros confirmados como *Felis catus* prosseguem para a **Fase IV** (Seção 3.5), que executa a *reidentificação individual* contra o catálogo de indivíduos da colônia, finalidade declarada de todo o sistema.

A pertinência das quatro fases pode ser lida em chave informacional: cada uma consome o volume residual filtrado pela anterior, reduzindo agressivamente o custo computacional global em comparação a um único modelo “tudo em um” que tentasse reidentificação direta sobre o fluxo bruto. Em termos de risco de engenharia, essa decomposição isola os modos de falha: uma queda de desempenho na detecção é diagnosticável separadamente de uma queda na classificação ou na re-ID, o que é informação crítica para o procedimento de avaliação do Capítulo 4. A Figura 1 consolida em forma de Diagrama de Fluxo de Dados (DFD) a arquitetura aqui descrita, explicitando os ramos de descarte (quadros vazios e fauna não-alvo), o passo de anonimização em conformidade com a LGPD discutido na Seção 3.3 e o catálogo de indivíduos da colônia como reservatório do estado do sistema.

Regime de execução

O regime de execução é deliberadamente simples e alinhado às condições materiais do Capítulo 2: **o pipeline é executado integralmente em um único servidor**, sobre janelas de mídia já consolidadas pelo ciclo de retirada de cartões. Não há requisito de latência baixa ou de processamento em tempo quase real: a cadência de análise é semanal ou quinzenal, compatível com a rotina de manejo da AEX Gatosdoc2 e suficiente para os fins de monitoramento populacional pretendidos. Esse desenho mantém o sistema reproduzível em uma única máquina de uso pessoal ou em um servidor institucional modesto, e elimina a necessidade de orquestração de filas, microserviços ou sincronização contínua entre nós de campo. A divisão borda-servidor explorada em Velasco-Montero *et al.* (2024) e Pishdast, Kalva e Tye (2025) permanece, no presente trabalho, como **otimização opcional**, restrita às eventuais unidades-piloto com SBC+NPU mencionadas na Seção 2.6; a descrição que se segue não pressupõe esse deslocamento, e a otimização completa por ponto é remetida aos trabalhos futuros do Capítulo 6.

Uso de modelos pré-treinados como decisão de escopo

Os modelos de visão empregados (MegaDetector na Fase II, SpeciesNet na Fase III, PetFace e o método de re-ID por partes do corpo na Fase IV) são utilizados em modo




Figura 1 – Diagrama de Fluxo de Dados (DFD) arquitetural do pipeline de visão computacional. As quatro fases operam em cascata sobre o acervo bruto consolidado pelo ciclo *offline-first*: o MegaDetector descarta quadros vazios e dispara o mascaramento da classe “pessoa” antes de qualquer persistência identificável (conformidade com a LGPD, Seção 3.3); o SpeciesNet descarta fauna não-alvo; e o estágio de reidentificação opera apenas sobre quadros confirmados como *Felis catus*, contra o catálogo de indivíduos da colônia, alimentando os relatórios operacionais da AEX Gatosdoc2.

pré-treinado (*as-is*), sem *fine-tuning* sobre dados locais do Campus 2 no escopo deste projeto. Três razões sustentam essa decisão. A primeira é o foco do trabalho na *concepção do sistema* e na sua *viabilidade técnica integrada*, e não na criação de um novo modelo de visão. A segunda é a maturidade documentada dos modelos generalistas escolhidos, que cobrem com folga as classes ecológicas observadas na Seção 2.1. A terceira é o limite prático imposto pelo cronograma: coleta sistemática de dataset local, anotação manual em volume e treinamento supervisionado são incompatíveis com o prazo de defesa e com o porte da equipe. A possibilidade de *fine-tuning* leve, em especial da re-ID sobre um pequeno dataset local de gatos cadastrados pelos voluntários, é discutida explicitamente como trabalho futuro no Capítulo 6, e o Capítulo 4 propõe, em consequência, testes deliberadamente *focados no problema e nos objetivos*, sem experimentos de retreinamento.

3.2 Fase I — Ingestão e triagem

A Fase I é responsável por converter a heterogeneidade de entrada descrita na Seção 3.1 em um **conjunto canônico de quadros** sobre o qual as fases seguintes possam operar sem precisar conhecer a origem específica de cada item. Sua função não é melhorar a qualidade das imagens em sentido fotográfico, mas garantir que o pipeline opere sobre uma representação uniforme e rastreável dos dados de campo, na qual cada quadro carrega consigo a informação necessária para que falhas possam ser diagnosticadas *a posteriori*. Em projetos de *camera trapping* em larga escala, esta etapa costuma absorver mais tempo de engenharia que as fases de inferência propriamente ditas, justamente porque dela depende a coerência de todo o restante (Vélez *et al.*, 2022; Bruce *et al.*, 2025).

Ingestão e extração de quadros

A ingestão começa pela transferência das mídias gravadas em cartões microSD para um diretório de trabalho do servidor, organizado por ponto e por janela de coleta. No caso operacional fixado pela Seção 2.6 — IPCAM comercial doméstica adaptada em modo *offline* —, as mídias chegam como arquivos de vídeo em formatos *H.264* ou *H.265* (contêineres *.mp4* ou *.mkv*). Eventuais unidades experimentais paralelas (*trail camera*, SBC com câmera, ESP32-CAM) entregam mídia em formatos distintos — *JPEG* estático, sequências numéricas, clipes proprietários — tratada por adaptadores dedicados de ingestão que produzem a mesma representação lógica de quadro a jusante. Sobre os arquivos de vídeo, o pipeline executa uma **extração de quadros** (*frame extraction*) com taxa de amostragem ajustada à dinâmica observada nos pontos: gatos comunitários permanecem junto aos potes de ração por janelas de segundos a alguns minutos, com movimentos relativamente lentos, o que permite amostrar em taxa significativamente inferior à do vídeo nativo — da ordem de poucos quadros por segundo, configurável por ponto — sem perda apreciável de informação relevante para detecção e re-ID. Essa decisão reduz drasticamente o volume de dados encaminhado às fases seguintes e elimina, já na entrada, quadros sucessivos quase idênticos.

Quando provenientes de unidades experimentais paralelas, imagens *JPEG* estáticas são tratadas como quadros já amostrados e ingressam diretamente no estágio seguinte da Fase I sem extração adicional. Ao fim deste sub-estágio, o pipeline trabalha sobre um **único formato lógico** — um quadro de imagem com metadados associados — independentemente da rota física pela qual o dado foi adquirido.

Filtragem de quadros não utilizáveis

Antes de invocar qualquer modelo de visão, a Fase I aplica duas filtrações *baratas* (*i.e.*, baseadas em estatísticas simples sobre histogramas) que eliminam quadros estruturalmente

não utilizáveis e evitam que esses casos consumam custo computacional desnecessário nas fases seguintes. A primeira é o descarte de quadros **completamente escuros ou completamente saturados**, comuns em pontos onde a iluminação ativa por NIR (Seção 2.4) gera quadros próximos ao módulo saturados e quadros distantes inteiramente pretos; essa filtragem é feita por inspeção simples da média e do desvio padrão de luminância do quadro. A segunda é o descarte de quadros sucessivos **quase idênticos** (deduplicação intra-evento), implementada por uma medida de diferença grosseira entre quadros adjacentes (por exemplo, soma de diferenças absolutas em uma versão reduzida do quadro). Essa deduplicação reconhece que um único evento de visita ao pote, capturado em vídeo, pode gerar dezenas de quadros amostrados quase indistinguíveis, e que apenas alguns deles agregam informação efetiva para o pipeline.

Cabe registrar que ambas as filtrações da Fase I são deliberadamente *conservadoras*: o objetivo aqui é eliminar apenas os casos cuja inutilidade é estatisticamente evidente, repassando qualquer quadro com alguma chance de conter informação útil para o detector da Fase II. Falsos positivos da Fase I — quadros não úteis que escapem desta filtragem inicial — têm custo modesto, porque serão descartados na Fase II; falsos negativos — quadros úteis erroneamente descartados aqui — são, em contraste, irrecuperáveis, e por isso a Fase I privilegia recall sobre precisão.

Normalização e metadados por ponto

Uma vez selecionados os quadros candidatos, a Fase I executa uma **normalização leve** cujo objetivo é compensar diferenças sistemáticas entre pontos (*e.g.*, diferentes regimes de exposição automática entre unidades, presença ou ausência de iluminação ativa por NIR, variações de *white balance* sob luz mista) sem alterar o conteúdo semântico do quadro. Essa normalização restringe-se a operações simples e reversíveis — equalização leve de histograma, ajuste de *white balance* sob NIR e redimensionamento para a resolução de entrada esperada pelos modelos da Fase II — e segue diretrizes comuns em projetos de aquisição heterogênea com câmeras de armadilha (Vélez *et al.*, 2022; Velasco-Montero *et al.*, 2024). A intenção declarada é *harmonizar* a entrada, e não *embelezar* os quadros: artefatos de iluminação NIR, granulação noturna e variações angulares por ponto são informações úteis para a detecção e a classificação posteriores e devem ser preservados.

A cada quadro canônico que sai da Fase I é anexado um conjunto mínimo de **metadados de proveniência**: identificador do ponto (P01–P10), tipologia da unidade que gerou a mídia (operacional ou experimental), *timestamp* extraído do nome do arquivo ou dos cabeçalhos EXIF, e parâmetros de extração e normalização aplicados. Esses metadados não fazem parte da inferência em si, mas são instrumentais para o procedimento de avaliação descrito no Capítulo 4 e para o diagnóstico de falhas por ponto: sem eles, um decaimento de desempenho restrito a um determinado abrigo ou a uma determinada tipologia de hardware seria invisível à análise agregada. Ao final da Fase I, portanto, o que segue para

a Fase II não é apenas uma coleção de imagens, mas uma coleção de quadros canônicos anotados com a informação mínima necessária para que o restante do pipeline opere e seja avaliável.

3.3 Fase II — Detecção generalista

A Fase II decide, para cada quadro canônico recebido da Fase I, se há ou não um animal presente e, em caso afirmativo, localiza a sua *bounding box*. Opera como uma válvula entre uma entrada potencialmente abundante (cartões com milhares de quadros amostrados) e uma saída relativamente escassa (quadros que efetivamente contêm um animal junto ao ponto de alimentação). Em projetos de *camera trapping* em larga escala é convergente o achado de que a maior parte do volume bruto coletado consiste em *ghost frames* acionados por vento, sombra ou variação térmica, e que filtrar esse volume antes de qualquer etapa de classificação fina é condição para a viabilidade operacional do restante do pipeline (Bruce *et al.*, 2025; Vélez *et al.*, 2022; Swanson *et al.*, 2015; Mulero-Pázmány *et al.*, 2025).

Escolha do modelo: MegaDetector como detector base

O modelo adotado nesta fase é o MegaDetector, integrado por meio da pilha *PyTorch-Wildlife* mantida pelo grupo *AI for Wildlife* da Microsoft Research (Hernandez *et al.*, 2024; Microsoft AI for Good, 2026). Trata-se de um detector treinado em grande volume de dados de *camera trapping* de diferentes biomas, projetado para detecção generalista de fauna em três classes amplas (animal, pessoa, veículo). Sua adoção é justificada por três fatores convergentes: disponibilidade pública dos pesos e da *pipeline* de inferência, maturidade documentada em campo e alinhamento natural com a Fase III, que assume para si a classificação multi-espécie. Esse desenho evita misturar em um único modelo o problema de rejeição de vazio e o de classificação fina, com modos de falha distintos e avaliação separável.

Em coerência com a decisão de escopo da Seção 3.1, o MegaDetector é utilizado sem *fine-tuning* sobre dados do Campus 2: o detector já cobre, com folga, a classe macroscópica “animal” que interessa nesta fase, e o esforço de coleta e anotação de um dataset local específico para detecção não traria ganho proporcional ao custo no escopo deste trabalho. Eventuais adaptações de domínio — por exemplo, ajuste sobre quadros NIR noturnos, regime em que o MegaDetector tem desempenho documentadamente inferior ao diurno — ficam registradas como trabalhos futuros no Capítulo 6.

Operação da fase no pipeline

Para cada quadro canônico entregue pela Fase I, o MegaDetector produz uma lista de detecções, cada uma composta por uma *bounding box*, uma classe macroscópica e um *score* de confiança. A Fase II aplica sobre essa saída um limiar de confiança configurável: quadros sem detecção acima do limiar são considerados negativos e removidos do fluxo; quadros com ao menos uma detecção válida da classe “animal” são marcados como positivos e seguem para a Fase III, acompanhados das coordenadas da *bounding box*, o que permite recortar a região de interesse e poupar à Fase III o custo de processar o quadro inteiro. Detecções das classes “pessoa” e “veículo”, quando presentes, são registradas apenas como metadado de diagnóstico (causa provável de disparo) e não propagam como entrada para a Fase III.

Anonimização de pessoas na origem

A presença incidental de transeuntes nos quadros é tratada por um passo de mascaramento automático aplicado imediatamente após a inferência do MegaDetector e antes de qualquer persistência em disco: as regiões correspondentes a detecções da classe “pessoa” são submetidas a um filtro gaussiano de alta intensidade, de modo que apenas versões anonimizadas dos quadros sejam gravadas no acervo do projeto. As coordenadas da *bounding box* permanecem como metadado operacional, sem qualquer associação a indivíduos identificáveis. O arranjo é coerente com o princípio de *privacy-by-design* adotado pelo projeto e atende, na origem, às obrigações decorrentes da Lei Geral de Proteção de Dados (Lei nº 13.709/2018); o detalhamento jurídico-operacional foge ao escopo técnico deste capítulo.

Limites conhecidos da Fase II e mitigações

A literatura aponta dois limites principais do MegaDetector em configuração padrão. O primeiro é o desempenho relativamente inferior em quadros noturnos sob iluminação NIR, em que o contraste entre animal e fundo é menor e o detector tende a produzir mais falsos negativos (Velasco-Montero *et al.*, 2024; Mulero-Pázmány *et al.*, 2025); a mitigação adotada é configurar o limiar de confiança por modo de captura (diurno versus noturno) e estratificar a avaliação do Capítulo 4 por horário, para que eventuais quedas de mAP em regime noturno apareçam explicitamente nos resultados. O segundo é o comportamento em *full-frame versus crop*: quando o animal ocupa fração muito pequena ou muito grande da imagem, o detector pode produzir caixas imprecisas ou falhar; a mitigação é parametrizar tamanhos mínimo e máximo de *bounding box* e estratificar a avaliação por distância média ao animal por ponto, sem alteração do modelo em si. Ao final da Fase II, o que segue para a Fase III é um subconjunto significativamente menor de quadros, cada um acompanhado da região de interesse sobre a qual a classificação multi-espécie precisa operar.

3.4 Fase III — Classificação de espécie

A Fase III recebe da Fase II quadros com detecções da classe macroscópica “animal” e tem como função única discriminar a espécie de cada detecção. Por estarem dispostos no solo e em formato aberto, os potes de ração do Campus 2 atraem rotineiramente fauna não-alvo — gambás (*Didelphis albiventris*), quatis (*Nasua nasua*), lagartos teiú, pombos, aves nativas e, criticamente, o felino silvestre gato-mourisco (*Herpailurus yagouaroundi*) (Gonçalves; Machado *et al.*, 2025; Cove *et al.*, 2022). Submeter indiscriminadamente essas espécies à reidentificação individual da Fase IV, treinada e validada apenas para *Felis catus*, produziria identificações falsas e contaminação persistente do histórico da colônia.

Escolha do modelo: SpeciesNet como classificador base

O modelo adotado nesta fase é o SpeciesNet, classificador hierárquico de espécies treinado em centenas de datasets de *camera trapping* ao redor do mundo, liberado em código aberto pelo *Google Research* (Google Research, 2026). Três fatores justificam sua escolha. Primeiro, foi desenhado para a tarefa exata desta fase: classificação de espécies sobre recortes de animais previamente detectados, em condições típicas de *camera trapping* (iluminação variável, ângulos não controlados, ocasional NIR), e não em fotografia controlada. Segundo, sua hierarquia taxonômica interna permite consumir a saída em diferentes níveis de generalidade — da família ao indivíduo — o que é útil ao filtro deste pipeline: quando o modelo não chega à espécie com confiança suficiente, ainda assim entrega a família ou a ordem. Terceiro, sua disponibilidade pública e integração com a pilha *PyTorch-Wildlife* usada na Fase II tornam a adoção operacionalmente simples.

Em linha com a decisão de escopo da Seção 3.1, o SpeciesNet é utilizado sem *fine-tuning* sobre dados do Campus 2. A cobertura do modelo abrange com folga as espécies de fauna não-alvo observadas em campo — gambás e quatis são classes bem representadas em datasets neotropicais incorporados ao treinamento — e tampouco há motivo para esperar falha sistemática no reconhecimento de *Felis catus*, classe abundante no treinamento global. Eventual *fine-tuning* leve sobre um conjunto representativo do Campus 2 fica registrado como trabalho futuro no Capítulo 6.

Operação da fase no pipeline

Para cada detecção recebida da Fase II, o SpeciesNet é aplicado sobre o recorte da *bounding box* e produz uma distribuição de probabilidade sobre seu vocabulário taxonômico. A política de decisão é conservadora: apenas detecções classificadas como *Felis catus* com confiança acima de um limiar configurável seguem para a Fase IV. Quadros classificados com confiança em outra espécie são registrados em uma base de fauna não-alvo — subproduto científico do projeto, retomado nos trabalhos futuros do Capítulo 6 — mas não avançam

no pipeline. Quadros sem classificação confiante (alta entropia distribuída entre várias classes plausíveis, ou baixa confiança concentrada em *Felis catus*) são roteados para uma fila de validação humana, em que voluntários da AEX Gatosdoc2 podem confirmar ou rejeitar a classificação por uma interface mínima de revisão.

A fila de validação humana cumpre dupla função: impede que casos duvidosos sigam para a re-ID e contaminem o histórico da colônia (papel operacional) e, ao longo do tempo, constitui um pequeno dataset rotulado do domínio do Campus 2 (papel metodológico), que poderia, em trabalho futuro, alimentar *fine-tuning* leve do SpeciesNet ou reavaliação dos limiares de confiança das Fases II e III. No escopo deste projeto, a fila é tratada apenas como camada de contenção, sem que as decisões algorítmicas das fases posteriores dependam dela.

Tratamento de espécies próximas e do gato-mourisco

Caso particular merecedor de menção explícita é o do *Herpailurus yagouaroundi*: felino silvestre nativo, de porte similar ao do gato doméstico em alguns indivíduos, presente em fragmentos urbanos da região central de São Paulo (Gonçalves; Machado *et al.*, 2025). Trata-se exatamente do cenário em que uma classificação binária “gato versus não-gato” seria semanticamente correta mas operacionalmente desastrosa, por misturar duas espécies distintas no estágio de re-ID. O SpeciesNet, treinado sobre vocabulário taxonômico abrangente, contempla a espécie no seu repertório e é capaz de distinguir as duas em condições adequadas de iluminação e ângulo. Em condições degradadas (NIR, ângulo oblíquo, oclusão parcial), é razoável esperar saídas de baixa confiança e, portanto, encaminhamento para a fila de validação humana — comportamento aceitável para fins do projeto.

Ao final da Fase III, segue para a Fase IV um subconjunto ainda menor de quadros: aqueles em que houve detecção válida de animal na Fase II, a classificação multi-espécie convergiu de forma confiante para *Felis catus* e, quando acionada, a validação humana confirmou essa classificação. É sobre esse subconjunto, e somente sobre ele, que a tarefa-fim do sistema pode operar com taxas de falso positivo aceitáveis.

3.5 Fase IV — Reidentificação individual

A Fase IV é a tarefa-fim do pipeline e a justificativa de existência de todo o sistema. Recebida do estágio anterior uma coleção depurada de quadros confiantemente classificados como *Felis catus*, seu objetivo é, para cada quadro, atribuir um identificador individual ao animal — ou registrar, com a devida cautela, que o indivíduo observado não é compatível com nenhum dos cadastrados, hipótese que aciona o protocolo de curadoria humana descrito ao final desta seção. A reidentificação individual é o passo que transforma um detector genérico de fauna em um sistema de monitoramento populacional, permitindo responder às

perguntas que efetivamente interessam ao manejo da colônia: quantos indivíduos distintos visitam cada ponto, com que frequência, com que sobreposição entre pontos e com que continuidade temporal.

Decomposição da tarefa: face e flanco

A literatura recente em re-ID de carnívoros pequenos converge em recomendar que a tarefa não seja tratada como problema único de *embedding* corporal global, mas decomposta em conjuntos de *features* discriminativas distintas, combináveis em decisão final ponderada. Para *Felis catus* em ambiente comunitário, dois conjuntos têm sustentação empírica direta: a face, com sua estrutura ocular, nasal e auricular específica, e o flanco, com seu padrão de pelagem, contorno corporal e — no caso de colônias submetidas a CED — a marcação por corte reto da ponta da orelha (*ear-tipping*). Essa decomposição é a abordagem proposta por Akbar, Rees e Fleming (2025) para re-ID por partes do corpo em felinos pequenos, alinhada à disponibilização do dataset PetFace, focado em reconhecimento facial de animais de companhia (Shinoda; Shiohara, 2024). A robustez da pelagem como atributo de re-ID é validada em larga escala no dataset WildlifeReID-10k (Adam *et al.*, 2024).

Em decorrência, a Fase IV é composta por dois subprocessos paralelos sobre o mesmo quadro recortado: re-ID por face, baseado em PetFace, e re-ID por flanco, baseado no método de partes do corpo de Akbar, Rees e Fleming (2025). Cada subprocesso produz um ranqueamento dos indivíduos do catálogo da colônia ordenados por similaridade ao quadro analisado; a decisão final combina os dois ranqueamentos por regra simples de fusão (média ponderada de *scores* normalizados, ou eleição quando há concordância no topo do Rank-1), priorizando o subprocesso cuja entrada esteja em condições geometricamente mais favoráveis (face frontal disponível versus apenas flanco visível).

Modelos pré-treinados e catálogo da colônia

Em coerência com a decisão de escopo da Seção 3.1, ambos os subprocessos são executados com modelos pré-treinados sem *fine-tuning* sobre dados do Campus 2. A *pipeline* pública do PetFace e a implementação de referência de Akbar, Rees e Fleming (2025) são aplicadas *as-is* sobre os recortes da Fase III, produzindo *embeddings* (vetores de características densos) que são comparados, por distância no espaço de embedding, contra o catálogo de embeddings dos indivíduos cadastrados. O catálogo é construído a partir de fotografias cadastrais dos animais já submetidos ao protocolo CED da AEX Gatosdoc2 (resumido na Seção 2.1), processadas uma única vez pelos mesmos modelos e armazenadas como referência permanente no servidor. A atualização do catálogo — inclusão de novos indivíduos, retirada de animais que deixaram a colônia — é tarefa operacional dos voluntários, mediada pela mesma interface da fila de validação humana da

Fase III. Eventual *fine-tuning* leve dos dois modelos sobre o conjunto cadastral local fica registrado como trabalho futuro no Capítulo 6.

Saída da fase: Rank- e tratamento de novos indivíduos

Para cada quadro processado, a Fase IV produz uma lista ranqueada dos k indivíduos do catálogo mais similares ao animal observado, acompanhada de seus *scores* de similaridade fundidos entre face e flanco. A política de decisão é cautelosa, em linha com a postura conservadora das fases anteriores. Quando o indivíduo do Rank-1 apresenta similaridade acima de um limiar configurável e margem confortável sobre o Rank-2, o pipeline atribui automaticamente o identificador correspondente e o adiciona ao histórico do indivíduo. Quando a similaridade do Rank-1 é alta mas a margem para o Rank-2 é estreita — caso típico em colônias com forte parentesco e padrões de pelagem similares —, o registro é encaminhado para curadoria humana, com a lista ranqueada exibida ao voluntário para decisão. Quando nenhum indivíduo do catálogo supera o limiar mínimo, o registro é marcado como “novo indivíduo candidato” e fica retido para curadoria, em que a equipe da AEX Gatosdoc2 decide se corresponde a um animal recém-incorporado ainda não cadastrado ou a um falso negativo do filtro multi-espécie da Fase III.

O desenho cumpre dois objetivos. O primeiro é evitar que o pipeline invente identidades: a atribuição automática só ocorre em alta confiança, e os demais casos seguem para curadoria humana. O segundo é manter o catálogo auditável: cada identidade automaticamente atribuída fica acompanhada do *score* de similaridade e da margem para o segundo colocado, e cada decisão humana fica registrada com data e identificador do voluntário, formando uma trilha mínima de auditoria que será incorporada à implementação futura do sistema. A confiabilidade dos modelos isoladamente e do pipeline integrado é estimada no Capítulo 4 por meio de mAP, F_1 e Rank-k apurados sobre datasets públicos representativos das condições esperadas no Campus 2.

3.6 Síntese e ponte com a metodologia

As quatro fases descritas neste capítulo formam um pipeline cuja lógica de conjunto é mais importante que qualquer um de seus modelos individuais. A Fase I (Seção 3.2) absorve as mídias entregues pela tipologia operacional — vídeo H.264/H.265 gravado em cartão microSD pela IPCAM adaptada — e a converte em um conjunto canônico de quadros anotados com metadados de proveniência por ponto. A Fase II (Seção 3.3) usa o MegaDetector como filtro generalista para descartar agressivamente *ghost frames* e quadros vazios, comprimindo o volume de entrada em uma ou duas ordens de grandeza. A Fase III (Seção 3.4) emprega o SpeciesNet para discriminar a espécie do animal detectado, filtrando a fauna não-alvo característica do Campus 2 e encaminhando apenas registros confiantes de *Felis catus* adiante. A Fase IV (Seção 3.5) executa a reidentificação individual com

PetFace e com o método de partes do corpo de [Akbar, Rees e Fleming \(2025\)](#), combinando face e flanco em decisão ranqueada contra o catálogo da colônia, com curadoria humana acionada nos casos duvidosos. O resultado é a transformação de uma massa bruta de mídia em série temporal estruturada de *visitas individuais por ponto*, que é exatamente a informação necessária para os fins de manejo declarados no Capítulo 1.

Em coerência com a decisão arquitetural por tipologia única (Seção 2.6), o pipeline é executado integralmente em servidor único, sobre janelas históricas já consolidadas pelo ciclo *offline-first* de retirada de cartões. Nenhuma das quatro fases pressupõe processamento em borda, e a sequência de execução é estritamente serial. A possibilidade de deslocar a Fase II para a borda permanece como otimização opcional, retomada como trabalho futuro no Capítulo 6; sua eventual adoção alteraria somente *onde* a Fase II é executada, não *como* o restante do pipeline opera. Essa simplicidade arquitetural mantém o sistema reproduzível em uma única máquina e está alinhada à escala e ao prazo de um projeto de graduação.

Com o pipeline assim consolidado em quatro fases e em uma única máquina, o Capítulo 4 desenvolve o protocolo de avaliação correspondente, restrito a datasets públicos já disponíveis e organizado em torno das quatro fases aqui descritas; o Capítulo 5 apresenta os resultados preliminares dessa avaliação e o Capítulo 6 retoma as limitações e os trabalhos futuros decorrentes, em particular a coleta sistemática de dados no Campus 2.

4 METODOLOGIA EXPERIMENTAL

4.1 Objetivos e postura

A avaliação visa estimar a viabilidade técnica do pipeline definido no Capítulo 3, sem coleta de campo no Campus 2. Em consequência, restringe-se a **datasets públicos consolidados** de *camera trapping* e re-identificação animal (Beery; Horn; Perona, 2018; Tabak *et al.*, 2019; Norouzzadeh *et al.*, 2018; Shinoda; Shiohara, 2024; Adam *et al.*, 2024): anotações por equipes especializadas, protocolos reproduzíveis e resultados publicados que viabilizam comparação externa. A coleta sistemática no Campus 2, a rotulagem em volume e a construção do catálogo da colônia integram a implementação futura (Capítulo 6).

Quatro perguntas orientam o protocolo, uma por fase. **Fase II:** o MegaDetector discrimina quadros com animal de quadros vazios em material representativo de fauna sinantrópica? **Fase III:** o SpeciesNet, sobre os recortes da Fase II, discrimina *Felis catus* de classes ecologicamente próximas (procyonidae, didelphidae, felinos silvestres de pequeno porte)? **Fase IV:** a combinação de PetFace com o método de partes do corpo de Akbar; Rees; Fleming (2025) produz Rank- k compatível com decisão automática em regime de alta confiança? **Pipeline:** a execução em cascata mantém a coerência de funil prevista, reduzindo volume e elevando confiança a cada estágio?

A postura é **operacional**, não comparativa de modelos: os componentes selecionados no Capítulo 3 operam em modo pré-treinado (*as-is*), com limiares iniciados nos valores padrão dos mantenedores e ajustados, quando necessário, com base nas matrizes de confusão e taxas de abstenção observadas. As métricas adotadas são as consagradas em cada subtarefa (mAP para detecção, F_1 e matriz de confusão para classificação, Rank- k e taxa de detecção de novo para re-ID), permitindo situar o sistema em relação à literatura.

4.2 Datasets públicos

A seleção dos datasets adotados segue três critérios: aderência à tarefa de cada fase, representatividade ecológica do contexto sinantrópico brasileiro (Fases II e III) e disponibilidade de protocolo padronizado de avaliação. A Tabela 1 sintetiza as fichas técnicas; todos são distribuídos sob *Community Data License Agreement* permissiva ou licença acadêmica, com agregação dos três primeiros no portal LILA BC (LILA BC, 2026).

Fases II e III

O **Caltech Camera Traps (CCT)** (Beery; Horn; Perona, 2018) é a referência primária: 243k imagens de 140 câmeras com 21 classes ecologicamente próximas da fauna

Tabela 1 – Datasets públicos selecionados para a avaliação do pipeline.

Dataset	Volume	Anotação	Licença	Função no estudo
<i>Caltech CT</i> (Beery; Horn; Perona, 2018)	243 k img / 21 cls	<i>bbox</i> + espécie	CDLA perm.	Deteção (II); classificação (III)
<i>NACTI</i> (Tabak <i>et al.</i> , 2019)	3,7 M img / 28 cls	espécie (bbox parcial)	CDLA perm.	Par crítico <i>F. catus/L. rufus</i> (III)
<i>Snapshot Serengeti</i> (Norouzzadeh <i>et al.</i> , 2018)	7,1 M img / 61 cls	espécie + contagem	CDLA perm.	Descarte de quadros vazios (II)
<i>PetFace</i> (Shinoda; Shiohara, 2024)	257 k indiv. div.	identidade + raça	acadêmica	Re-ID por face (IV)
<i>WildlifeReID-10k</i> (Adam <i>et al.</i> , 2024)	10 k indiv. / 33 esp.	identidade + <i>split</i>	acadêmica	Re-ID por flanco (IV)

esperada (gambás, guaxinins, esquilos). A divisão treino/teste oficial separa imagens por local de captura, simulando a aplicação de um classificador genérico em ambiente novo. O **NACTI** (Tabak *et al.*, 2019) fornece o par discriminativo crítico *Felis catus* vs. *Lynx rufus*, examinando a confusão entre felinos domésticos e silvestres de pequeno porte. O **Snapshot Serengeti** (Norouzzadeh *et al.*, 2018), com cerca de três quartos de quadros vazios, atua como conjunto de teste severo para o descarte de *ghost frames* na Fase II.

Fase IV

O **PetFace** (Shinoda; Shiohara, 2024) é a referência primária para re-ID por face: 257 k indivíduos, subconjunto significativo de gatos domésticos, protocolos oficiais *closed-set* e *open-set*. O **WildlifeReID-10k** (Adam *et al.*, 2024) cobre dez mil indivíduos em ~33 espécies, com divisões *time-aware* e *similarity-aware* que controlam vazamento entre treino e teste, e é a base para o subprocesso de re-ID por flanco e padrão de pelagem (método de partes do corpo de Akbar; Rees; Fleming, 2025).

Limites de extrapolação

Nenhum dataset selecionado foi coletado em ambiente urbano cooperativo com câmeras integradas a abrigos comunitários. As Fases II e III tampouco contemplam o conjunto exato de fauna não-alvo do Campus 2 — em particular, o gato-mourisco (*Herpailurus yagouaroundi*) está ausente, embora classes ecologicamente equivalentes (*Lynx rufus*, *Leopardus pardalis*) estejam presentes. Os resultados configuram **estimativas de limite superior** do desempenho esperado em condições brasileiras, devendo ser lidos como

evidência de viabilidade técnica e não como predição operacional. A validação em condições do Campus 2 fica reservada à implementação futura.

4.3 Protocolo por fase

O protocolo organiza-se em quatro blocos (um por fase) mais um teste integrador ponta-a-ponta. Cada bloco fixa partição de dados, condições controladas (separação temporal, separação de indivíduos, estratificação de iluminação) e **baseline mínimo** de comparação. A Tabela 2 sumariza fase, dataset, modelo principal e baseline. Limiares finais, sementes e hiperparâmetros de inferência são registrados como itens a fixar no momento da execução, dado o caráter conceitual desta etapa.

Tabela 2 – Mapeamento protocolar entre fase, dataset, modelo principal e baseline.

Fase	Tarefa	Dataset(s)	Modelo principal	Baseline
I	Triagem por movimento	janela sintética	filtro embarcado	—
II	Deteção de fauna	CCT, Snapshot Ser.	MegaDetector (<i>zero-shot</i>)	YOLOv8n (COCO → “animal”)
III	Triagem de espécie	CCT, NACTI	SpeciesNet (<i>zero-shot</i>)	ResNet binário (<i>transfer</i>)
IV	Re-ID individual	PetFace, WildlifeReID-10k	PetFace + partes (sobre WildlifeReID-10k)	ResNet-50 ImageNet <i>frozen</i>
E2E	Cascata completa	janela sintética	Pipeline I→IV	aplicação ingênua

Fase I — triagem por movimento

Filtro embarcado, sem inferência semântica. A aferição é indireta, pela razão de redução de quadros vazios observada na entrada da Fase II durante o teste ponta-a-ponta (Seção 4.3), com a proporção de vazios herdada do Snapshot Serengeti.

Fase II — detecção de fauna

Baseia-se em CCT e Snapshot Serengeti. Modalidade *zero-shot*: o conjunto de teste oficial é usado integralmente, dividido em estratos (dia *vs.* noite, positivos *vs.* negativos). Limiar inicial conforme documentação do detector, com ajuste local explícito quando o *recall* noturno for excessivamente baixo. O baseline é o YOLOv8 nano pré-treinado em COCO, com mapeamento das classes animais para a meta-classe “animal”.

Fase III — triagem de espécie

Opera sobre dois subconjuntos: (i) o CCT — quadros positivos (*F. catus* ou equivalentes) para teste de aceitação e demais classes para teste de rejeição — e (ii) o NACTI, do qual se extrai o par crítico *F. catus*/*L. rufus*. O SpeciesNet é avaliado em *zero-shot* sob seu mapeamento taxonômico nativo; o resultado é binarizado *a posteriori* em “é *F. catus*” *vs.* “não é *F. catus*”, preservando a espécie predita para análise qualitativa. O baseline é um classificador binário (gato *vs.* não-gato) por *transfer learning* curto sobre ResNet-ImageNet, com partição de treino oficial do CCT.

Fase IV — re-identificação individual

Conduzida sobre os *splits* oficiais de PetFace e WildlifeReID-10k em dois regimes. No ***closed-set***, o catálogo é construído a partir dos respectivos *galleries* oficiais e o teste consulta o *query set*; reporta-se Rank-1 e Rank-5. No ***open-set***, parte dos indivíduos do *query set* é removida do catálogo e passa a operar como distratora; reporta-se, além de Rank-1, a **taxa de detecção de novo** (fração de distratores cuja similaridade máxima fica abaixo do limiar de rejeição τ). O controle de vazamento é estrito por indivíduo, nativamente garantido pelos *splits time-aware* e *similarity-aware*. Baseline: *embedding* corporal global por ResNet-50 ImageNet *frozen*.

Teste ponta-a-ponta

Uma **janela sintética** é montada a partir dos próprios datasets, concatenando quadros vazios e positivos do Snapshot Serengeti (Fases I e II), positivos de *F. catus* e fauna não-alvo de CCT e NACTI (Fase III), e indivíduos catalogados e distratores de PetFace e WildlifeReID-10k (Fase IV). As proporções seguem o padrão empírico recorrente em *camera trapping* urbano peri-natural (Vélez *et al.*, 2022): 60–80% de vazios, 15–30% de animais, até 10% de gatos identificáveis. A janela atravessa o pipeline completo; em cada estágio registram-se volume descartado, volume aprovado e custo computacional médio por quadro, gerando a curva de eficiência. Variante de controle: a mesma janela é submetida à aplicação ingênua das fases sobre todos os quadros, e os dois traços são contrastados.

4.4 Métricas e regras de reporte

A escolha das métricas reflete a tarefa de cada fase. Na **Fase II**, adota-se a precisão média (mAP) sobre uma única classe “animal”, reportada em duas variantes (mAP@0.5 e mAP@0.5:0.95) e estratificada por iluminação (dia, noite com infravermelho próximo) e por tipo de quadro (positivo, negativo). Na **Fase III**, reportam-se o F_1 da classe alvo *Felis catus* (após binarização *a posteriori*) e a acurácia balanceada do problema multiclasse

subjacente, acompanhados da matriz de confusão completa — instrumento adequado para identificar, classe a classe, os pares de espécies onde o modelo erra com mais frequência. Na **Fase IV**, reportam-se Rank-1 e Rank-5 (*closed-set*) e a taxa de detecção de novo (*open-set*), com o limiar τ calibrado sobre catalogados para fixar uma taxa de falsa rejeição em torno de 5%; a avaliação sobre distratores ocorre só após τ fixado, evitando uso indireto do teste para ajuste de parâmetros.

Em paralelo às métricas de qualidade, mede-se o **custo computacional** médio por quadro de cada modelo em cada fase, em milissegundos sobre o ambiente de execução adotado (apenas inferência, descontando carregamento de modelo e leitura de disco), com reporte por estrato (dia, noite, quadros vazios). A regra de interpretação dos comparativos é descritiva, não estatística: as diferenças entre modelo principal e baseline são classificadas qualitativamente em três faixas — pequena (poucos pontos percentuais), moderada (5–15 p.p.) e grande (>15 p.p.). Uma fase é considerada **conceitualmente validada** quando o modelo principal supera seu baseline por margem moderada ou grande; diferença pequena ou favorável ao baseline configura ponto de revisão arquitetural, a ser endereçado em trabalho futuro com dados reais do Campus 2.

4.5 Reprodutibilidade

O ambiente de execução adotado é Python em ambiente virtual isolado, com arquivo de *lock* de dependências (`requirements.txt` ou `environment.yml`) versionado junto ao repositório. Os pesos pré-treinados são baixados explicitamente para diretório local antes da execução, com *checksums* registrados em `checksums.txt`, permitindo verificar que o modelo carregado em qualquer reexecução é idêntico ao da rodada original. Quatro grupos de dependências precisam ser fixados nominalmente: a *toolkit* de *deep learning* (PyTorch, com *tag* de *build* CUDA quando aplicável), as bibliotecas dos modelos (MegaDetector, SpeciesNet, PetFace, WildlifeReID-10k), as de manipulação de imagem (OpenCV, Pillow) e as de avaliação (scikit-learn, *pycocotools*). A fixação de *seed* ocorre em três pontos — inicialização de geradores pseudoaleatórios do Python e do NumPy, *seed* da *toolkit* de *deep learning* e embaralhamento de partições — a partir de um valor base único registrado no arquivo de configuração; experimentos com múltiplas rodadas (não previstos nesta etapa, mas tratados como trabalho futuro) usam *seeds* consecutivos.

A organização operacional prevê **cinco scripts** parametrizados por um único arquivo de configuração (JSON ou YAML) versionado junto ao repositório. O `run_phase2.py` carrega os *splits* de teste oficiais de CCT e Snapshot Serengeti, executa MegaDetector e o baseline YOLO genérico, aplica o mascaramento por *blur* das *bounding boxes* da classe “pessoa” (LGPD, Seção 3.3) antes de qualquer persistência, e produz em `out/phase2/` um CSV por modelo e estrato com mAP estratificada e custo médio. O `run_phase3.py` carrega os subconjuntos relevantes de CCT e NACTI, executa SpeciesNet e o baseline

binário, e produz F_1 , acurácia balanceada e matriz de confusão. O `run_phase4.py` carrega os *splits* oficiais de PetFace e WildlifeReID-10k, monta os catálogos *closed-set* e *open-set* e executa as configurações comparadas (face, flanco por partes do corpo, fusão tardia, baseline global). O `run_end2end.py` monta a janela sintética, executa pipeline em cascata e variante ingênua e gera os dados da curva de eficiência. Finalmente, o `compare_runs.py` consolida duas execuções em uma única tabela comparável, sinalizando regressões acima de um limiar configurável. Cada execução emite, ao final, um arquivo `run_metadata.json` contendo SHA do código, versão de Python, plataforma, *seed* e *hash* da configuração. Os códigos completos dos cinco scripts estão no Apêndice [B](#).

5 RESULTADOS PRELIMINARES E DISCUSSÃO

5.1 Posicionamento

OBS: Os números, tabelas e gráficos deste capítulo são estimativas de faixa, extraídas da literatura recente dos modelos e datasets adotados, e servem de template para a substituição direta pelos valores medidos após a execução do protocolo do Capítulo 4.

Os resultados aqui apresentados foram derivados de três fontes: as faixas de desempenho reportadas pelos próprios mantenedores dos modelos pré-treinados (Shinoda; Shiohara, 2024; Adam *et al.*, 2024; Akbar; Rees; Fleming, 2025), a literatura recente de classificação multi-espécie em *camera trapping* (Tabak *et al.*, 2019; Norouzzadeh *et al.*, 2018) e a curva empírica de eficiência reportada por Vélez *et al.* (2022) para pipelines de duas etapas. As faixas mantêm coerência com o regime de avaliação em distribuição próxima da treinada (dados do portal LILA BC) e devem ser lidas como **limite superior** do desempenho operacional esperado no Campus 2, conforme discutido na Seção 4.2.

O capítulo organiza-se na ordem das fases (Seções 5.2–5.4), seguida do teste integrador (Seção 5.5) e da discussão consolidada (Seção 5.6). Em todos os casos, o reporte combina uma tabela quantitativa (faixas estimadas) e, quando aplicável, uma figura conceitual. Os comparativos com os baselines seguem a classificação qualitativa fixada na Seção 4.4: diferença pequena, moderada ou grande.

5.2 Fase II — detecção genérica de fauna

A Tabela 3 consolida o desempenho estimado do MegaDetector sobre os *splits* de teste oficiais do CCT e do Snapshot Serengeti, estratificado por iluminação. O baseline YOLOv8 nano genérico segue a mesma estratificação.

Tabela 3 – Desempenho estimado da Fase II por modelo e estrato. *OBS: faixas teóricas a substituir após execução.*

Modelo / estrato	mAP@0.5	mAP@0.5:0.95	Recall (nom.)	Recall (ajust.)
MegaDetector — diurno	0,85–0,92	0,60–0,70	0,82–0,90	0,88–0,94
MegaDetector — noturno	0,70–0,80	0,45–0,55	0,65–0,78	0,75–0,85
MegaDetector — total	0,78–0,86	0,52–0,62	0,75–0,84	0,82–0,90
YOLOv8 gen. — diurno	0,55–0,70	0,35–0,50	0,50–0,68	0,58–0,72
YOLOv8 gen. — noturno	0,40–0,55	0,25–0,38	0,35–0,52	0,45–0,58
YOLOv8 gen. — total	0,48–0,62	0,30–0,44	0,42–0,60	0,52–0,65

A diferença estimada na mAP@0.5:0.95 total ($\sim 0,55$ vs. $\sim 0,37$) configura-se como **grande** pelo critério da Seção 4.4, consistente com a expectativa arquitetural de que um detector treinado especificamente em *camera trapping* supere um detector generalista de objetos no mesmo regime de iluminação variável. A queda de desempenho entre estratos diurno e noturno — estimada em ~ 10 p.p. para o MegaDetector e ~ 15 p.p. para o baseline — reflete a dificuldade conhecida de detecção sob iluminação infravermelha próxima, e justifica a possibilidade de ajuste local do limiar noturno prevista no protocolo.

5.3 Fase III — triagem de espécie

A Tabela 4 apresenta a matriz de confusão estimada do SpeciesNet sobre classes representativas do CCT e do NACTI, com destaque para o par crítico *Felis catus* vs. *Lynx rufus* (NACTI), ecologicamente análogo, no Brasil, à distinção entre gato doméstico e felinos silvestres de pequeno porte.

Tabela 4 – Matriz de confusão estimada da Fase III. Linhas: classe verdadeira; colunas: classe predita. *OBS: faixas plausíveis com base na literatura recente; substituir pelos valores medidos.*

Verdadeira ↓ / Predita →	<i>F. cat.</i>	<i>L. ruf.</i>	<i>P. lot.</i>	<i>D. virg.</i>	<i>Sciurus</i>	F_1
<i>Felis catus</i> (CCT+NACTI)	0,90	0,06	0,02	0,01	0,01	0,88
<i>Lynx rufus</i> (NACTI)	0,12	0,82	0,03	0,02	0,01	0,80
<i>Procyon lotor</i> (CCT)	0,02	0,03	0,89	0,04	0,02	0,86
<i>Didelphis virginiana</i> (CCT)	0,03	0,02	0,05	0,87	0,03	0,85
<i>Sciurus</i> sp. (CCT)	0,01	0,01	0,03	0,03	0,92	0,90
Acurácia balanceada (SpeciesNet)						0,87
Acurácia balanceada (baseline binário gato/não-gato)						0,78

A leitura conjunta da diagonal e do par crítico permite duas observações conceituais. Primeiro, a discriminação direta entre *Felis catus* e as três classes não-felinas (*P. lotor*, *D. virginiana*, *Sciurus*) tende a ser elevada (acertos $\geq 0,87$), pois envolve diferenças morfológicas marcadas que o SpeciesNet captura nativamente. Segundo, e mais relevante para o cenário brasileiro, a confusão entre *F. catus* e *L. rufus* estimada em $\sim 12\%$ das instâncias projetadas como “é *F. catus*” corresponde ao caso ecológico em que o pipeline mais provavelmente confundirá gato doméstico com felinos silvestres de pequeno porte (gato-do-mato, gato-mourisco). Esse ponto sustenta a recomendação — já registrada como trabalho futuro — de *fine-tuning* específico sobre fauna brasileira após acumulado mínimo de campo. O ganho estimado de ~ 9 p.p. na acurácia balanceada do SpeciesNet sobre o baseline binário é **moderado-grande**, justificando a opção arquitetural pelo classificador multi-espécie.

5.4 Fase IV — re-identificação individual

A Tabela 5 consolida o desempenho estimado da Fase IV por configuração (face, corpo por partes, fusão tardia e baseline) e por regime (*closed-set* restrito ao catálogo; *open-set* com distratores). A Figura 2 apresenta a curva CMC (Rank- k vs. k) conceitual associada.

Tabela 5 – Desempenho estimado da Fase IV por configuração e regime. *OBS: faixas teóricas a substituir após execução do protocolo.*

Configuração	Rank-1 (closed)	Rank-5 (closed)	Rank-1 (open)
Face (PetFace)	0,75–0,85	0,88–0,94	0,55–0,68
Corpo (partes sobre WildlifeReID-10k)	0,68–0,80	0,82–0,90	0,48–0,62
Fusão tardia face + corpo	0,82–0,90	0,92–0,96	0,60–0,72
Baseline ResNet-50 <i>frozen</i>	0,40–0,55	0,58–0,72	0,25–0,40




Figura 2 – Curva CMC conceitual da Fase IV (regime *closed-set*). *OBS: traços ilustrativos, a substituir pelas curvas medidas.*

A diferença entre fusão tardia e baseline genérico é **grande** em todos os regimes (~ 35 p.p. no Rank-1 *closed* e ~ 30 p.p. no *open*), o que valida conceitualmente o uso de *embeddings* especializados em pets e em fauna em vez de descritores gerais. A queda esperada do regime *closed* para o *open* (~ 22 p.p. na fusão tardia) é o efeito conhecido de introduzir distratores: parte das consultas passa a ter similaridade máxima sobre indivíduos errados quando o verdadeiro está fora do catálogo, e o limiar τ converte essa similaridade alta-mas-incorreta em rejeição válida. A combinação face + corpo supera cada componente isolado por ~ 5 – 7 p.p., consistente com a complementaridade de pistas: a face é estável em close-ups frontais e sensível a oclusão, enquanto o flanco é robusto a pose e iluminação mas depende de área visível mínima.

5.5 Teste ponta-a-ponta

A Tabela 6 reporta o efeito acumulado da cascata sobre a janela sintética descrita na Seção 4.3 (10 000 quadros, com 70% de vazios, 25% de fauna geral e 5% de *F. catus* identificáveis). A Figura 3 sintetiza visualmente a curva de quadros remanescentes *vs.* custo acumulado.

Tabela 6 – Funil da cascata na janela sintética de 10 000 quadros. *OBS: volumes derivados das taxas de retenção médias das Tabelas 3–5; substituir após execução.*

Estágio	Entrada	Aprovados	Retenção	Custo médio (ms/q.)
Fase I (movimento)	10 000	4 200	42%	2
Fase II (MegaDetector)	4 200	1 180	28%	35
Fase III (SpeciesNet)	1 180	310	26%	28
Fase IV (face + corpo)	310	295	95%	55
Cascata adotada	295 / 10 000 quadros aprov.		2,95%	11 (média ponderada)
Aplicação ingênua	(todas as fases sobre todos os quadros)		—	120

Duas inferências simples emergem dos números acima. (i) Há **redução de ordem de grandeza no volume** entre a entrada bruta e a saída da Fase III, em consonância com o desenho de funil previsto no Capítulo 3: cada fase filtra o conteúdo majoritariamente irrelevante para a fase seguinte (vazios na II, fauna não-alvo na III), e apenas a fração já pré-filtrada chega à etapa de re-ID, computacionalmente mais cara. (ii) A **economia de custo computacional** estimada para a cascata em relação à aplicação ingênua aproxima-se de **10×** (~ 11 ms/quadro *vs.* ~ 120 ms/quadro): a Fase IV, apesar de ser a mais cara individualmente, é executada sobre menos de 3% dos quadros originais, enquanto na aplicação ingênua incidiria sobre todos. Os custos absolutos dependem do *hardware* adotado, mas a razão entre cascata e aplicação ingênua é uma propriedade arquitetural do pipeline, e tende a se preservar entre plataformas.

OBS: Os valores absolutos de tempo serão fixados pela execução em ambiente real; a relação cascata/ingênua é a métrica conceitual a ser preservada na substituição.

5.6 Discussão integrada

A Tabela 7 consolida, por fase, o comparativo entre pipeline principal e baseline, com a classificação qualitativa da magnitude da diferença adotada na Seção 4.4.

Três pontos sintetizam a leitura conceitual dos resultados. **Primeiro**, todas as quatro fases superam seus baselines por margem grande, o que sustenta empiricamente — na medida do que faixas de literatura permitem — a opção arquitetural pelo pipeline em cascata com modelos especializados em vez de uma única rede genérica. **Segundo**, o efeito de funil previsto no Capítulo 3 confirma-se na curva de eficiência: redução de duas ordens de grandeza no volume e razão estimada de cerca de 10× na carga computacional entre




Figura 3 – Curva conceitual de eficiência do pipeline em cascata em comparação à aplicação ingênua das fases sobre todos os quadros: queda monotônica do volume (eixo y esquerdo, escala logarítmica) contrastada com o custo computacional acumulado (eixo y direito). *OBS: traços ilustrativos; substituir pelas curvas empíricas após execução.*

Tabela 7 – Síntese comparativa por fase. *OBS: Δ aproximado, magnitude qualitativa; substituir após execução real.*

Fase	Métrica	Principal	Baseline	Δ	Magnitude / leitura
II	mAP@0.5:0.95	0,52–0,62	0,30–0,44	$\sim +0,18$	grande — validada
III	F_1 macro	0,85–0,90	0,68–0,78	$\sim +0,12$	grande — validada
IV	Rank-1 <i>closed</i>	0,82–0,90	0,40–0,55	$\sim +0,35$	grande — validada
IV	Rank-1 <i>open</i>	0,60–0,72	0,25–0,40	$\sim +0,30$	grande — validada
E2E	quadros sobreviventes	0,01–0,05	0,30–0,50	—	cascata efetiva

cascata e aplicação ingênua, com a Fase IV restrita a uma fração pequena dos quadros originais. **Terceiro**, os pontos de fragilidade são previsíveis e localizam-se nas mesmas áreas que a literatura identifica para sistemas de *camera trapping*: queda de *recall* sob iluminação infravermelha, confusão entre espécies ecologicamente próximas (par crítico *F. catus*/*L. rufus*) e degradação no regime *open-set* pela introdução de distratores.

O **efeito de extrapolação** do laboratório para o Campus 2 é o ponto crítico do trabalho. Os datasets adotados não foram coletados em ambiente urbano cooperativo, e o gato-mourisco — relevante no contexto brasileiro — está ausente. As faixas estimadas devem, portanto, ser lidas como limite superior: o desempenho operacional efetivo no Campus 2 será função, em primeiro lugar, da qualidade da coleta inicial e da rotulagem da colônia (Capítulo 6), e, em segundo lugar, da capacidade do pipeline de absorver, via *fine-tuning* subsequente, as condições específicas de iluminação, distância focal e composição de fauna do local. Essa lacuna não invalida o desenho atual; demarca, ao contrário, a fronteira entre a contribuição conceitual desta monografia e a contribuição empírica que a

implementação futura precisa entregar.

6 CONCLUSÃO E TRABALHOS FUTUROS

6.1 Síntese

A monografia abordou o problema de manejo de colônia de gatos no Campus 2 da USP São Carlos do ponto de vista da engenharia de sistemas, propondo um **pipeline de visão computacional em quatro fases** — triagem por movimento, detecção genérica de fauna, classificação de espécie e re-identificação individual — como instrumento de redução de fricção operacional para o projeto *Gatosdoc2*. O Capítulo 2 caracterizou os pontos de instalação e fixou a tipologia única de *kit* de câmeras IP comerciais domésticas alimentadas por baterias, com comunicação Wi-Fi entre câmera e *gateway* local. O Capítulo 3 desenhou o pipeline em servidor único, sem inferência embarcada na borda, e fixou MegaDetector, SpeciesNet, PetFace e o método de partes do corpo de Akbar; Rees; Fleming sobre WildlifeReID-10k como componentes principais, recortando os pontos de *tradeoff* privacidade-LGPD, custo de inferência e cobertura taxonômica. O Capítulo 4 formalizou o protocolo de avaliação restrito a datasets públicos, com baseline mínimo por fase e teste integrador sobre janela sintética. O Capítulo 5 reportou as estimativas conceituais correspondentes, com elementos fictícios devidamente sinalizados, e discutiu as implicações arquiteturais.

6.2 Contribuições

A primeira contribuição é **arquitetural**: a especificação ponta-a-ponta de um pipeline em cascata que combina três bibliotecas pré-treinadas heterogêneas (camera trapping, re-ID de pets, re-ID de fauna selvagem) sob uma única convenção de entrada/saída, com tratamento explícito do mascaramento de pessoas exigido pela LGPD antes de qualquer persistência identificável. A segunda é **metodológica**: um protocolo de avaliação restrito a datasets públicos, com baseline mínimo por fase e janela sintética como sucedâneo controlado da operação de campo, que permite demonstrar viabilidade técnica antes de comprometer recursos com coleta sistemática. A terceira é **operacional**: a definição de uma tipologia única de *kit* de instrumentação por baterias e câmeras IP comerciais, com matriz de pontos prevista no Apêndice A e estrutura de scripts reproduzíveis no Apêndice B, que reduzem a barreira de entrada da implementação para a equipe *Gatosdoc2* sem exigir competência técnica especializada em *deep learning* para a operação cotidiana. Em conjunto, as três contribuições convertem o problema — até então tratado em planilhas e visitas pontuais — em um sistema escalável e auditável, e estabelecem a base sobre a qual o impacto **social** (transparência da gestão da colônia, comunicação com a comunidade

do Campus) e de **saúde pública** (detecção precoce de fauna sinantrópica relevante para zoonoses) pode ser construído de forma incremental.

6.3 Limitações

A primeira limitação é o **caráter conceitual** do trabalho: o pipeline foi especificado e avaliado sobre datasets públicos, sem coleta de campo no Campus 2 e sem rotulagem da colônia. Os resultados do Capítulo 5 são, portanto, estimativas de limite superior, e o desempenho operacional efetivo será função da qualidade da coleta inicial e do esforço de rotulagem. A segunda é a **lacuna taxonômica**: o gato-mourisco (*Herpailurus yagouaroundi*) e o gato-do-mato (*Leopardus tigrinus*) — ecologicamente relevantes no Campus 2 — estão ausentes dos datasets adotados, restando classes equivalentes (*Lynx rufus*, *Leopardus pardalis*) como aproximação. A terceira é o **vazamento por origem**: MegaDetector e SpeciesNet foram treinados parcialmente sobre dados do portal LILA BC, ao qual pertencem CCT e Snapshot Serengeti, o que tende a sobrestimar a generalização das Fases II e III para condições brasileiras. A quarta é a **ausência de validação por sementes múltiplas**: as comparações são descritivas, não estatísticas, dado o custo de múltiplas execuções nesta etapa do projeto. As quatro limitações são tratadas como condições de contorno explícitas; nenhuma invalida o desenho proposto, mas todas delimitam o que esta monografia entrega e o que a implementação futura precisa entregar.

6.4 Trabalhos futuros

A implementação efetiva do sistema no Campus 2 organiza-se em quatro frentes encadeadas, que retomam, na ordem de execução, as lacunas identificadas na Seção 6.3.

A primeira frente é a **coleta de campo e a construção de um dataset local**. A prioridade imediata é a instalação dos *kits* de câmeras nos pontos P01–P10 caracterizados no Apêndice A, com rotulagem mínima dos primeiros meses de operação. O acúmulo esperado — da ordem de dezenas de milhares de quadros por trimestre — permite construir um dataset local cuja distribuição reflita as condições reais de iluminação, distância focal e composição de fauna do Campus, e que servirá tanto à substituição dos elementos fictícios do Capítulo 5 quanto a recursos para a comunidade brasileira de *camera trapping*, hoje sub-representada em datasets públicos.

A segunda frente é o ***fine-tuning* dos modelos**. Sobre o dataset local consolidado, o caminho de trabalho mais promissor é o *fine-tuning* curto do SpeciesNet para o subconjunto efetivo de fauna não-alvo do Campus 2, com destaque para o par crítico *F. catus*/felinos silvestres de pequeno porte, e a calibração do limiar τ da Fase IV sobre indivíduos efetivamente catalogados pela equipe *Gatosdoc2*. O *fine-tuning* do MegaDetector é tratado

como recurso de reserva, a ser acionado apenas se o desempenho noturno medido ficar consistentemente abaixo do estimado no Capítulo 5.

A terceira frente é a **validação empírica e a iteração arquitetural**. Com dataset local e modelos refinados, o protocolo do Capítulo 4 é reexecutado, substituindo as faixas teóricas do Capítulo 5 pelos valores medidos e classificando cada fase como validada ou ponto de revisão arquitetural. Os pontos de revisão alimentam uma iteração focada: troca pontual de modelo, mudança de regime de *closed-set* para *open-set* contínuo, ou inclusão de heurísticas de pós-processamento por contexto temporal (sequências de quadros do mesmo indivíduo na mesma sessão).

A quarta frente é a **integração com o *Gatosdoc2* e os desdobramentos de pesquisa**. A integração consiste em conectar o pipeline ao fluxo de trabalho do *Gatosdoc2*, com painel para a equipe (lista de indivíduos detectados, fila de validação humana da Fase III, candidatos a novo indivíduo da Fase IV) e canal de comunicação com a comunidade do Campus (relatórios mensais agregados, sem dados pessoais por força da LGPD). Como desdobramento de pesquisa, três linhas se abrem: estudo longitudinal da dinâmica da colônia com base nos registros do sistema, replicação do protocolo em outros campi da USP — fornecendo evidência multissítio para o desenho proposto — e ampliação do escopo do classificador para fauna sinantrópica não-felina relevante para vigilância de zoonoses urbanas no contexto brasileiro.

REFERÊNCIAS

- ADAM, L. *et al.* WildlifeReID-10k: Wildlife re-identification dataset with 10k individual animals. **arXiv preprint arXiv:2406.09211**, 2024. Disponível em: <https://arxiv.org/abs/2406.09211>.
- AKBAR, R. R. S.; REES, M.; FLEMING, P. A. Body-part-based individual feral cat identification from camera trap images using deep learning. **Ecological Informatics**, 2025. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1574954125002675>.
- AnimalCLEF. **AnimalCLEF 2026 — Animal Re-identification Challenge**. 2026. Disponível em: <https://www.kaggle.com/competitions/animal-clef-2026>.
- BASTOS, F.; FARIAS, M. R. de. Cat-transmitted sporotrichosis by *sporothrix brasiliensis*: Focus on its potential transmission routes and epidemiological profile. **Medical Mycology**, 2025. Disponível em: <https://academic.oup.com/mmy/article/doi/10.1093/mmy/myaf051/8158997>.
- BEERY, S.; HORN, G. V.; PERONA, P. Recognition in Terra Incognita. In: **Proceedings of the European Conference on Computer Vision (ECCV)**. [S.l.: s.n.], 2018. p. 456–473. Disponível em: https://openaccess.thecvf.com/content_ECCV_2018/papers/Beery_Recognition_in_Terra_ECCV_2018_paper.pdf.
- BEUKES, M. *et al.* Refining camera trap surveys for mammal detection and diversity assessment in the Baviaanskloof Catchment, South Africa. **Wild**, v. 2, n. 2, p. 15, 2025. Disponível em: <https://www.mdpi.com/3042-4526/2/2/15>.
- BRASIL. **Lei Federal nº 13.426, de 30 de março de 2017**. 2017. Dispõe sobre a política de controle da natalidade de cães e gatos.
- BRASIL. **Lei Federal nº 15.046, de 17 de dezembro de 2024**. 2024.
- BRASIL. **Decreto Federal nº 12.439, de 17 de abril de 2025**. 2025. Diário Oficial da União, Brasília. Institui o Programa Nacional de Proteção e Manejo Populacional Ético de Cães e Gatos e o Cadastro Nacional de Animais Domésticos. Acesso em: 17 maio 2026. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2023-2026/2025/Decreto/D12439.htm.
- BRUCE, T. *et al.* Large-scale and long-term wildlife research and monitoring using camera traps: a continental synthesis. **Biological Reviews**, 2025. Disponível em: <https://onlinelibrary.wiley.com/doi/10.1111/brv.13152>.
- CECCHETTI, M.; NELLI, L. Planning and optimizing neutering programs for free-roaming cat populations. **Journal of Applied Ecology**, 2025. Disponível em: <https://besjournals.onlinelibrary.wiley.com/doi/10.1111/1365-2664.70052>.
- CFMV. **Resolução CFMV nº 1.595, de 26 de março de 2024**. 2024. Altera a Resolução CFMV nº 877/2008 e autoriza o corte reto da ponta da orelha de felinos para identificação. Disponível em: <https://crmvsp.gov.br/nova-resolucao-do-cfmv-redefine-identificacao-de-felinos-castrados/>.

- CFMV. **Resolução CFMV nº 1.596, de 26 de março de 2024**. 2024. Diretrizes gerais para programas de esterilização cirúrgica com finalidade de manejo populacional. Disponível em: https://ses.sp.bvs.br/wp-content/uploads/2024/04/U_RS-CFMV-1.596_260324.pdf.
- COLOMBO, S. A.; CARVALHO, J. A. de *et al.* The emergence of new *sporothrix brasiliensis* genotypes in current epidemic of sporotrichosis in southeastern Brazil. **Mycoses**, 2024. Disponível em: <https://onlinelibrary.wiley.com/doi/10.1111/myc.13792>.
- CORDIER, C. P. *et al.* Camera trap research in Africa: A systematic review. **Global Ecology and Conservation**, 2022. Disponível em: <https://linkinghub.elsevier.com/retrieve/pii/S2351989422003286>.
- COVE, M. V. *et al.* Counting the Capital's cats: Estimating drivers of abundance of free-roaming cats with a novel hierarchical model. **Ecological Applications**, 2022. Disponível em: <https://esajournals.onlinelibrary.wiley.com/doi/10.1002/eap.2790>.
- FERREIRA, B. G. G. O. *et al.* The TND-RTM protocol for controlling sporotrichosis in a free-roaming cat colony in southern Brazil. **Research in Veterinary Science**, 2026. Disponível em: <https://linkinghub.elsevier.com/retrieve/pii/S0034528826000603>.
- FERROGLIO, E. *et al.* An integrated approach to an emerging problem: Implementing a whole year of camera trap survey in evaluating the impact of wildlife on tick abundance. **Transboundary and Emerging Diseases**, 2024. Disponível em: <https://onlinelibrary.wiley.com/doi/10.1155/2024/4064855>.
- GONÇALVES, L. S.; MACHADO, D. de S. *et al.* The wildcat that lives in me: A review on free-roaming cats (*felis catus*) in Brazil, focusing on research priorities, management, and welfare. **Animals**, v. 15, n. 2, p. 190, 2025. Disponível em: <https://www.mdpi.com/2076-2615/15/2/190>.
- Google Research. **Where wild things roam: Identifying wildlife with SpeciesNet**. 2026. Disponível em: <https://research.google/blog/where-wild-things-roam-identifying-wildlife-with-speciesnet/>.
- GUNTHER, I. *et al.* Reduction of free-roaming cat population requires high-intensity neutering in spatial contiguity to mitigate compensatory effects. **Proceedings of the National Academy of Sciences**, v. 119, n. 15, 2022. Disponível em: <https://pnas.org/doi/full/10.1073/pnas.2119000119>.
- HERNANDEZ, A. *et al.* PyTorch-Wildlife: A collaborative deep learning framework for conservation. **arXiv preprint arXiv:2405.12930**, 2024. Disponível em: <https://arxiv.org/abs/2405.12930>.
- HERRERA, D.; COVE, M. V. Prey selection and predation behavior of free-roaming domestic cats (*felis catus*) in an urban ecosystem: Implications for urban cat management. **Biological Conservation**, 2022. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0006320722000568>.
- HIGA, L. T.; ARAÚJO, S. M. *et al.* A prospective study of *toxoplasma*-positive pregnant women in southern Brazil: a health alert. **Transactions of the Royal Society of Tropical Medicine and Hygiene**, 2010. Disponível em: <https://academic.oup.com/trstmh/article-lookup/doi/10.1016/j.trstmh.2010.01.006>.

JUNQUEIRA, A. N. N.; GALERA, P. D. Evaluation of population management based on trap–neuter–return and trap–neuter–adoption practices in a free-roaming cat colony in the Federal District, Brazil. **Animals**, v. 14, n. 17, p. 2478, 2024. Disponível em: <https://www.mdpi.com/2076-2615/14/17/2478>.

KMETIUK, L. B. *et al.* Occurrence of antibodies anti-*toxoplasma gondii* among sheltered and free-roaming cats within a university campus. **Semina: Ciências Agrárias**, v. 42, n. 3 supl. 1, p. 1685, 2021. Disponível em: <http://www.uel.br/revistas/uel/index.php/semagrarias/article/view/41050>.

KREISLER, R. E.; CORNELL, H. N.; LEVY, J. K. Decrease in population and increase in welfare of community cats in a 23-year Trap-Neuter-Return program in Key Largo, FL: The ORCAT program. **Frontiers in Veterinary Science**, v. 6, p. 7, 2019. Disponível em: <https://www.frontiersin.org/article/10.3389/fvets.2019.00007/full>.

LEVY, J. K.; GALE, D. W.; GALE, L. A. Evaluation of the effect of a long-term trap-neuter-return and adoption program on a free-roaming cat population. **Journal of the American Veterinary Medical Association**, v. 222, n. 1, p. 42–46, 2003. Disponível em: <https://avmajournals.avma.org/view/journals/javma/222/1/javma.2003.222.42.xml>.

LI, Y. *et al.* Estimates of wildlife killed by free-ranging cats in China. **Biological Conservation**, 2021. Disponível em: <https://linkinghub.elsevier.com/retrieve/pii/S0006320720309873>.

LILA BC. **Labeled Information Library of Alexandria: Biology and Conservation**. 2026. Acesso em: 17 maio 2026. Disponível em: <https://lila.science/>.

LOSS, S. R.; WILL, T.; MARRA, P. P. The impact of free-ranging domestic cats on wildlife of the United States. **Nature Communications**, v. 4, p. 1396, 2013. Disponível em: <https://www.nature.com/articles/ncomms2380>.

MEEK, P.; BALLARD, G.; FALZON, G. The higher you go the less you will know: placing camera traps high to avoid theft will affect detection. **Remote Sensing in Ecology and Conservation**, 2016. Disponível em: <https://onlinelibrary.wiley.com/doi/10.1002/rse2.28>.

MEEK, P. D. *et al.* Camera trap theft and vandalism: occurrence, cost, prevention and implications for wildlife research and management. **Remote Sensing in Ecology and Conservation**, v. 5, n. 2, p. 160–168, 2019. Disponível em: <https://zslpublications.onlinelibrary.wiley.com/doi/10.1002/rse2.96>.

Microsoft AI for Good. **PyTorch-Wildlife (microsoft/CameraTraps)**. 2026. Repositório oficial. Acesso em: 17 maio 2026. Disponível em: <https://github.com/microsoft/CameraTraps>.

MOLL, R. J. *et al.* The effect of camera-trap viewshed obstruction on wildlife detection: implications for inference. **Wildlife Research**, v. 47, n. 2, p. 158–165, 2020. Disponível em: <https://www.publish.csiro.au/wr/WR19004>.

MULERO-PÁZMÁNY, M. *et al.* Addressing significant challenges for animal detection in camera trap images: a novel deep learning-based approach. **Scientific Reports**, v. 15, 2025. Disponível em: <https://www.nature.com/articles/s41598-025-90249-z>.

- NAKASHIMA, Y.; YAJIMA, G. Modeling spatiotemporal variations in the density of unmarked populations using camera trap data: An application to free-roaming cats. **Biological Conservation**, 2025. Disponível em: <https://linkinghub.elsevier.com/retrieve/pii/S0006320724004762>.
- NATOLI, E. *et al.* Evaluation of unowned domestic cat management in Italy: A 30-year experience. **Frontiers in Veterinary Science**, 2019. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC6398421/>.
- NOROUZZADEH, M. S. *et al.* Automatically identifying, counting, and describing wild animals in camera-trap images with deep learning. **Proceedings of the National Academy of Sciences**, v. 115, n. 25, 2018. Disponível em: <https://www.pnas.org/doi/full/10.1073/pnas.1719367115>.
- OpenIPC Project. **OpenIPC: an alternative open firmware for IP cameras**. 2025. <https://openipc.org/>. Acessado em 2026.
- PASSOS, G. B.; BOVENDORP, R. Population dynamics and predation by free-ranging cats (*felis catus*) in a Brazilian university campus: Implications for urban wildlife management. **Revista Contemporânea**, v. 5, n. 11, 2025. Disponível em: <https://ojs.revistacontemporanea.com/ojs/index.php/home/article/view/9553>.
- PISHDAST, H.; KALVA, H.; TYE, D. AI-enabled smart camera traps for wildlife monitoring in African ecosystems. In: **Proceedings of the 2025 ACM Conference**. [S.l.: s.n.], 2025. Disponível em: <https://dl.acm.org/doi/10.1145/3748699.3749780>.
- RIGOUDY, N. *et al.* The DeepFaune initiative: a collaborative effort towards the automatic identification of French fauna in camera-trap images. **bioRxiv**, 2023. Disponível em: <https://www.biorxiv.org/content/10.1101/2022.03.15.484324v3>.
- SANTIAGO, M. G.; COSTA, D. *et al.* *Sporothrix brasiliensis* and cats: understanding the disease and the promising potential of veterinary antifungal vaccination. **Animal Diseases**, 2025. Disponível em: <https://link.springer.com/10.1186/s44149-025-00208-4>.
- SARGENT, A. J. *et al.* Raspberry Pi nest cameras: An affordable tool for remote behavioral and conservation monitoring of bird nests. **Ecology and Evolution**, v. 11, n. 21, p. 14585–14597, 2021. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8571635/>.
- SCHIEFER, C. A. *et al.* Trap–neuter–return and return-to-field programs for managing community cats at Florida animal shelters. **Journal of Shelter Medicine and Community Animal Health**, v. 4, 2025. Disponível em: <https://jsmcah.org/index.php/jasv/article/view/126>.
- SCHNEIDER, S.; TAYLOR, G. W.; KREMER, S. C. Deep learning object detection methods for ecological camera trap data. In: **IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS)**. [S.l.: s.n.], 2018. Disponível em: <https://ieeexplore.ieee.org/document/8575770/>.
- SEIDLITZ, A. *et al.* Optimising camera trap height and model increases detection and individual identification rates for a small mammal, the numbat. **Australian Mammalogy**, 2020. Disponível em: <https://connectsci.au/am/article/43/2/226/36159/>.

SHINODA, R.; SHIOHARA, K. PetFace: A large-scale dataset and benchmark for animal identification. **arXiv preprint arXiv:2407.13555 (ECCV 2024)**, 2024. Disponível em: <https://arxiv.org/abs/2407.13555>.

SPEHAR, D. D.; WOLF, P. J. Back to school: An updated evaluation of the effectiveness of a long-term trap-neuter-return program on a University's free-roaming cat population. **Animals**, v. 9, n. 10, p. 768, 2019. Disponível em: <https://www.mdpi.com/2076-2615/9/10/768>.

SWANSON, A. *et al.* Snapshot Serengeti, high-frequency annotated camera trap images of 40 mammalian species in an African savanna. **Scientific Data**, v. 2, p. 150026, 2015. Disponível em: <https://www.nature.com/articles/sdata201526>.

TABAK, M. A. *et al.* Machine learning to classify animal species in camera trap images: Applications in ecology. **Methods in Ecology and Evolution**, v. 10, n. 4, 2019. Disponível em: <https://besjournals.onlinelibrary.wiley.com/doi/10.1111/2041-210X.13120>.

TIDDEMAN, B. P. *et al.* Automated video-based capture of crustacean fisheries data using low-power hardware. **Sensors**, v. 23, n. 18, p. 7897, 2023. Disponível em: <https://www.mdpi.com/1424-8220/23/18/7897>.

VECCHI, P. L. G. S. *et al.* Ethical population management of feral cats on universities campuses based on TNR protocol. **PUBVET**, v. 16, 2022. Disponível em: <https://ojs.pubvet.com.br/index.php/revista/article/view/3008>.

VELASCO-MONTERO, D. *et al.* Reliable and efficient integration of AI into camera traps for smart wildlife monitoring based on continual learning. **Ecological Informatics**, v. 83, p. 102815, 2024. Disponível em: <https://linkinghub.elsevier.com/retrieve/pii/S1574954124003571>.

VÉLEZ, J. *et al.* Choosing an appropriate platform and workflow for processing camera trap data using artificial intelligence. **arXiv preprint arXiv:2202.02283**, 2022. Disponível em: <https://arxiv.org/pdf/2202.02283.pdf>.

Wildlife Insights. **Wildlife Insights AI**. 2026. Acesso em: 17 maio 2026. Disponível em: <https://www.wildlifeinsights.org/about-wildlife-insights-ai>.

APÊNDICES

APÊNDICE A – MATRIZ BRUTA DE INFRAESTRUTURA DOS PONTOS P01–P10

A Tabela 8 reproduz, em formato tabular, a matriz bruta de levantamento de infraestrutura dos dez pontos candidatos a instalação de câmeras de *camera trapping* no Campus 2 da USP São Carlos. Cada linha corresponde a um ponto identificado durante o reconhecimento de campo conduzido em conjunto com voluntários da AEX Gatosdoc2; as colunas registram atributos físicos do local (cobertura, iluminação, edifício), atributos operacionais (movimento de pessoas, vandalismo) e atributos de infraestrutura técnica (tomada elétrica, cobertura Wi-Fi USP, cobertura 4G, insolação direta para painel solar, presença prévia de câmeras de segurança institucionais, presença de outros animais). As coordenadas geográficas aproximadas obtidas por GPS de telefone celular são apresentadas separadamente na Tabela 9. Essa matriz alimenta a discussão de tipologias do Capítulo 2 e a decisão arquitetural consolidada na Seção 2.6.

Tabela 8 – Matriz bruta de infraestrutura dos pontos P01–P10 do Campus 2 da USP São Carlos. Atributos físicos, operacionais e de infraestrutura técnica.

ID	Local	Edifício	Cobert.	Luz not.	Mov.	Vand.	Tom.	Dist. tom.	Wi- Fi USP	4G	Sol >4h	Câm. seg.	Outros anim.
P01	Atrás cantina Eng. Comp.	Eng. Comp.	Semi-coberto	Fraca	Médio	Baixo	Sim	5 m	Sim	Sim	Sim	Sim	Sim
P02	Atrás prédio Eng. Comp.	Eng. Comp.	Aberto	Fraca	Quase nulo	Baixo	Não	—	Sim	Sim	Sim	Não	Sim
P03	Atrás Anfiteatro	Bloco didático	Aberto	Fraca	Médio	Baixo	Não	—	Sim	Sim	Sim	Não	Sim
P04	Lado Anfiteatro	Bloco didático	Semi-coberto	Boa	Alto	Médio	Não	—	Sim	Sim	Sim	Não	Sim
P05	Corredor Anfiteatro / WCs	Bloco didático	Coberto	Ausente	Alto	Médio	Sim	10 m	Sim	Sim	Não	Não	Sim
P06	Corredor Biblioteca	Biblioteca	Coberto	Boa	Alto	Médio	Sim	5 m	Sim	Sim	Sim	Não	Sim
P07	Entre prédios Bloco Laranja	Bloco didático	Semi-coberto	Boa	Baixo	Baixo	Não	—	Sim	Sim	Sim	Não	Sim
P08	Bloco Amarelo / Entre prédios	Bloco didático	Semi-coberto	Fraca	Quase nulo	Baixo	Não	—	Sim	Sim	Sim	Não	Sim
P09	Atrás prédio Aero 1	Aeronáutica	Aberto	Ausente	Quase nulo	Baixo	Não	—	Sim	Sim	Sim	Não	Sim

Continua na próxima página

Tabela 8 – Continuação da página anterior

ID	Local	Edifício	Cobert.	Luz not.	Mov.	Vand.	Tom.	Dist. tom.	Wi- Fi USP	4G	Sol >4h	Câm. seg.	Outros anim.
P10	Atrás Aero 2	prédio Aeronáutica	Aberto	Fraca	Quase nulo	Baixo	Não	—	Sim	Sim	Sim	Não	Sim

Tabela 9 – Coordenadas geográficas aproximadas dos pontos P01–P10, obtidas por GPS de telefone celular. Precisão limitada à do dispositivo; não devem ser tomadas como referência cartográfica oficial.

ID	Latitude	Longitude	Altitude (m)
P01	−22,0000	−47,9333	832,8
P02	−22,0023	−47,9324	845,0
P03	−22,0019	−47,9314	847,1
P04	−22,0015	−47,9312	846,5
P05	−22,0012	−47,9310	844,0
P06	−21,9995	−47,9335	848,0
P07	−21,9988	−47,9340	850,5
P08	−21,9982	−47,9348	852,0
P09	−22,0040	−47,9355	855,0
P10	−22,0045	−47,9362	856,2

A leitura cruzada da matriz com a discussão de tipologias revela três agrupamentos operacionais bem definidos. Em primeiro lugar, P01, P05 e P06 são pontos com tomada elétrica próxima, cobertura física e fluxo médio a alto de pessoas, candidatos naturais a tipologia IPCAM com alimentação por rede elétrica e armazenamento em cartão microSD. Em segundo lugar, P02, P03 e P07 a P10 são pontos sem tomada próxima, com cobertura aberta ou semi-coberta e insolação direta suficiente para alimentação por painel solar de pequeno porte, candidatos a câmera autônoma alimentada por bateria. Em terceiro lugar, P04 isola-se como ponto de movimento alto, cobertura semi-coberta e iluminação noturna boa, candidato a tipologia híbrida com possibilidade de instalação de SBC para processamento em borda caso a disponibilidade de tomada seja resolvida pela equipe da Prefeitura do Campus 2. Esses agrupamentos são a base operacional da Seção 2.6 e devem orientar a escolha de equipamento na fase de implantação.

Cabe registrar que as coordenadas declaradas na Tabela 9 têm precisão limitada à do GPS do telefone celular utilizado em campo e não devem ser tomadas como referência cartográfica oficial. Uma planta georreferenciada precisa dos pontos P01–P10 sobre o mapa institucional do Campus 2 está prevista como item de implantação — a Figura 4 reserva o espaço dessa planta como *placeholder* para inclusão futura.




Figura 4 – Planta georreferenciada dos pontos P01–P10 sobre o mapa institucional do Campus 2 (a produzir).

APÊNDICE B – CÓDIGOS

Reúnem-se os códigos dos cinco scripts da estrutura operacional descrita na Seção 4.5: três scripts por fase (Fases II, III e IV), um orquestrador ponta-a-ponta e um consolidador comparativo. As listagens omitem detalhes de *logging* e tratamento de exceções para preservar foco no fluxo de dados; o código efetivamente executado pode incluir trechos auxiliares que não alteram a semântica aqui descrita. A correspondência entre cada código e os módulos de `04_codigo/src/` é documentada no `README` daquele subprojeto.

B.1 Fase II — detecção (`run_phase2.py`)

Listing B.1 – `run_phase2.py` — MegaDetector e baseline YOLO sobre os *splits* oficiais de CCT e Snapshot Serengeti. O mascaramento por *blur* das caixas da classe “pessoa” é aplicado antes de qualquer escrita em disco (LGPD).

```

1  # run_phase2.py
2  # código da Fase II do pipeline -- detecção generalista com MegaDetector.
3  # Lê a janela canônica produzida pela Fase I e devolve um arquivo de detecções
4  # (uma linha por quadro, com bbox + classe + score). Inclui o passo de
5  # mascaramento (blur) das caixas da classe "pessoa" antes de qualquer
6  # persistência identificável, em conformidade com a LGPD.
7  import json, hashlib, csv
8  from pathlib import Path
9  from pytorch_wildlife.models import detection as pwd
10 from pipeline.io import iter_canonical_frames, write_anonymized_frame
11 from pipeline.privacy import blur_bbox # filtro gaussiano de alta intensidade
12
13 def main(cfg):
14     model = pwd.MegaDetectorV6(pretrained=True,
15                               weights_hash=cfg["weights_hash_md"])
16     model.eval()
17     thr = cfg["confidence_threshold"] # ex.: 0.20 (diurno) / 0.10 (noturno)
18     out_csv = Path(cfg["out_dir"]) / "phase2_detections.csv"
19
20     with out_csv.open("w", newline="") as f:
21         w = csv.writer(f)
22         w.writerow(["frame_id", "x", "y", "w", "h", "class", "score"])
23
24     for frame in iter_canonical_frames(cfg["in_dir"]):

```

```

25     dets = model.detect(frame.tensor, conf=thr)
26     keep_for_phase3 = []
27
28     for det in dets:
29         if det.cls == "person":
30             # LGPD: mascara ANTES de qualquer escrita em disco
31             frame.image = blur_bbox(frame.image, det.bbox,
32                                     sigma=cfg["blur_sigma"])
33             w.writerow([frame.id, *det.bbox, "person_masked", det.score])
34         elif det.cls == "vehicle":
35             w.writerow([frame.id, *det.bbox, "vehicle", det.score])
36         elif det.cls == "animal":
37             keep_for_phase3.append(det)
38             w.writerow([frame.id, *det.bbox, "animal", det.score])
39
40         # Persiste apenas o quadro já anonimizado
41         write_anonymized_frame(cfg["out_dir"], frame)
42
43         # Encaminha para a Fase III somente se houver detecção de animal
44         if keep_for_phase3:
45             json.dump({"frame_id": frame.id,
46                       "dets": [d.to_dict() for d in keep_for_phase3]},
47                       (Path(cfg["queue_dir"]) / f"{frame.id}.json").open("w")
48                       )
49
50     return out_csv
51
52 if __name__ == "__main__":
53     cfg = json.load(open("config/phase2.json"))
54     main(cfg)

```

B.2 Fase III — classificação (run_phase3.py)

Listing B.2 – run_phase3.py — SpeciesNet sobre recortes da Fase II; encaminhamento à Fase IV restrito a quadros confirmados como *F. catus*.

```

1  # run_phase3.py
2  # código da Fase III -- classificação multi-espécie com SpeciesNet.
3  # Lê a fila de detecções produzida pela Fase II, recorta a bbox e classifica
4  # a região de interesse. Só os quadros classificados como Felis catus são
5  # encaminhados para a Fase IV.
6  import json, csv
7  from pathlib import Path
8  from speciesnet import SpeciesNetClassifier
9  from pipeline.io import open_image, crop
10 from pipeline.taxonomy import is_felis_catus
11
12 def main(cfg):
13     clf = SpeciesNetClassifier(model_id=cfg["speciesnet_release"],
14                               taxonomy=cfg["taxonomy_csv"])
15     out_csv = Path(cfg["out_dir"]) / "phase3_classifications.csv"
16
17     with out_csv.open("w", newline="") as f:
18         w = csv.writer(f)
19         w.writerow(["frame_id", "bbox", "top1_class", "top1_score",
20                   "top5_classes", "is_felis_catus"])
21
22     for q in sorted(Path(cfg["queue_dir"]).glob("*.json")):
23         payload = json.load(q.open())
24         img = open_image(Path(cfg["frames_dir"]) /
25                           f"{payload['frame_id']}.jpg")
26         for det in payload["dets"]:
27             roi = crop(img, det["bbox"])
28             pred = clf.classify(roi, topk=5)
29             w.writerow([payload["frame_id"], det["bbox"],
30                         pred.top1.label, pred.top1.score,
31                         [p.label for p in pred.topk],
32                         is_felis_catus(pred.top1)])
33             if is_felis_catus(pred.top1):
34                 # Envia para a Fase IV
35                 json.dump({"frame_id": payload["frame_id"],
36                           "bbox": det["bbox"],
37                           "label": pred.top1.label,

```

```
38         "score": pred.top1.score},
39         (Path(cfg["reid_queue"]) /
40          f"{payload['frame_id']}_{{det['bbox'][0]}}.json"
41          ).open("w"))
42
43     return out_csv
44
45 if __name__ == "__main__":
46     cfg = json.load(open("config/phase3.json"))
47     main(cfg)
```

B.3 Fase IV — re-identificação (run_phase4.py)

Listing B.3 – run_phase4.py — fusão tardia entre *embedding* facial (PetFace) e *embedding* por partes do corpo sobre WildlifeReID-10k, com decisão *closed-set/open-set* por limiar τ calibrado em catalogados.

```

1  # run_phase4.py
2  # código da Fase IV -- reidentificação individual.
3  # Para cada recorte confirmado como Felis catus na Fase III, extrai
4  # embedding facial (PetFace) e embedding por partes do corpo
5  # (Akbar et al., 2025, sobre WildlifeReID-10k), aplica fusão tardia e
6  # compara contra o catálogo. Decide closed-set (Rank-k) e open-set
7  # (limiar de novidade calibrado em catalogados, conforme Seção 4.4).
8  import json, numpy as np, csv
9  from pathlib import Path
10 from reid.face import PetFaceEmbedder
11 from reid.body import BodyPartEmbedder # método de Akbar (2025)
12 from reid.catalog import IndividualCatalog
13 from reid.fusion import late_fusion
14 from pipeline.io import open_image, crop_face, crop_body
15
16 def main(cfg):
17     face = PetFaceEmbedder(cfg["petface_weights"])
18     body = BodyPartEmbedder(cfg["wildlife_weights"])
19     cat = IndividualCatalog.load(cfg["catalog_dir"])
20     tau = cfg["openset_threshold"] # calibrado sobre catalogados
21
22     out_csv = Path(cfg["out_dir"]) / "phase4_reid.csv"
23     with out_csv.open("w", newline="") as f:
24         w = csv.writer(f)
25         w.writerow(["frame_id", "bbox", "match_id", "rank1_dist",
26                    "rank5_ids", "is_novel"])
27
28     for q in sorted(Path(cfg["reid_queue"]).glob("*.json")):
29         p = json.load(q.open())
30         img = open_image(Path(cfg["frames_dir"]) /
31                           f"{p['frame_id']}.jpg")
32         roi_face = crop_face(img, p["bbox"]) # heurística por cabeça
33         roi_body = crop_body(img, p["bbox"])
34
35         e_face = face.embed(roi_face)
36         e_body = body.embed(roi_body)

```

```
37         e_fused = late_fusion(e_face, e_body, w_face=cfg["w_face"])
38
39         ranked = cat.rank(e_fused, k=5)
40         is_novel = ranked[0].dist > tau
41
42         w.writerow([p["frame_id"], p["bbox"],
43                     None if is_novel else ranked[0].id,
44                     ranked[0].dist,
45                     [r.id for r in ranked],
46                     is_novel])
47
48         if is_novel:
49             # quadro vai para fila de validação humana / cadastro
50             cat.stage_for_review(e_fused, p)
51
52     return out_csv
53
54 if __name__ == "__main__":
55     cfg = json.load(open("config/phase4.json"))
56     main(cfg)
```

B.4 Orquestrador ponta-a-ponta (run_end2end.py)

Listing B.4 – run_end2end.py — encadeia as quatro fases sobre a janela sintética e emite run_metadata.json reprodutível.

```

1  # run_end2end.py
2  # Orquestrador ponta-a-ponta: encadeia Fases I a IV em uma janela sintética
3  # e emite o run_metadata.json reprodutível exigido pelo Capítulo 4.
4  import json, time, hashlib, platform, subprocess
5  from pathlib import Path
6  from pipeline.phase1 import run_phase1
7  import run_phase2, run_phase3, run_phase4
8
9  def git_sha():
10     return subprocess.check_output(["git", "rev-parse", "HEAD"]).decode().strip()
11
12  def main(cfg):
13     t0 = time.time()
14     run_dir = Path(cfg["runs_dir"]) / f"run_{int(t0)}"
15     run_dir.mkdir(parents=True)
16
17     # Fase I -- ingestão e padronização
18     canonical = run_phase1.execute(cfg["ingest"], out=run_dir / "phase1")
19
20     # Fase II -- detecção + anonimização LGPD
21     cfg_p2 = {**cfg["phase2"], "in_dir": canonical, "out_dir": run_dir / "
22         phase2",
23         "queue_dir": run_dir / "queue_p3"}
24     run_phase2.main(cfg_p2)
25
26     # Fase III -- classificação multi-espécie
27     cfg_p3 = {**cfg["phase3"], "queue_dir": run_dir / "queue_p3",
28         "frames_dir": run_dir / "phase2",
29         "reid_queue": run_dir / "queue_p4",
30         "out_dir": run_dir / "phase3"}
31     run_phase3.main(cfg_p3)
32
33     # Fase IV -- reidentificação individual
34     cfg_p4 = {**cfg["phase4"], "reid_queue": run_dir / "queue_p4",
35         "frames_dir": run_dir / "phase2",
36         "out_dir": run_dir / "phase4"}

```

```
36     run_phase4.main(cfg_p4)
37
38     meta = {
39         "run_id": run_dir.name,
40         "started_at": t0,
41         "ended_at": time.time(),
42         "git_sha": git_sha(),
43         "python": platform.python_version(),
44         "platform": platform.platform(),
45         "seed": cfg["seed"],
46         "config_hash": hashlib.sha256(
47             json.dumps(cfg, sort_keys=True).encode()).hexdigest(),
48     }
49     (run_dir / "run_metadata.json").write_text(json.dumps(meta, indent=2))
50     return run_dir
51
52 if __name__ == "__main__":
53     cfg = json.load(open("config/end2end.json"))
54     main(cfg)
```

B.5 Consolidação de *runs* (compare_runs.py)

Listing B.5 – `compare_runs.py` — consolida principal e baseline em uma única tabela comparativa, com classificação automática da magnitude da diferença por fase.

```

1  # compare_runs.py
2  # Gera o relatório comparativo de dois runs do pipeline (principal vs baseline)
3  # consolidando as métricas das Fases II, III e IV em uma tabela única, no
4  # formato esperado pela Tabela 6 do Capítulo 4 (síntese baseline vs principal).
5  import json, csv
6  from pathlib import Path
7  from collections import defaultdict
8
9  import pandas as pd
10
11 def load_metrics(run_dir):
12     p2 = pd.read_csv(run_dir / "phase2" / "phase2_detections.csv")
13     p3 = pd.read_csv(run_dir / "phase3" / "phase3_classifications.csv")
14     p4 = pd.read_csv(run_dir / "phase4" / "phase4_reid.csv")
15     return {
16         "phase2_recall": p2.query("class == 'animal'").shape[0] /
17             max(1, p2.shape[0]),
18         "phase3_f1": compute_macro_f1(p3),
19         "phase4_rank1": (p4["match_id"].notna()).mean(),
20     }
21
22 def compute_macro_f1(df):
23     # macro-F1 sobre as classes presentes nos datasets adotados
24     # (Felis catus, Lynx rufus, Procyon lotor, Didelphis virginiana, Sciurus sp
25     # .)
26     classes = df["top1_class"].unique()
27     f1s = []
28     for c in classes:
29         tp = ((df["top1_class"] == c) & (df["true_class"] == c)).sum()
30         fp = ((df["top1_class"] == c) & (df["true_class"] != c)).sum()
31         fn = ((df["top1_class"] != c) & (df["true_class"] == c)).sum()
32         prec = tp / max(1, tp + fp)
33         rec = tp / max(1, tp + fn)
34         f1 = 2 * prec * rec / max(1e-9, prec + rec)
35         f1s.append(f1)
36     return sum(f1s) / max(1, len(f1s))

```

```
36
37 def main(principal_dir, baseline_dir, out_csv):
38     m_p = load_metrics(Path(principal_dir))
39     m_b = load_metrics(Path(baseline_dir))
40
41     rows = []
42     for k in ("phase2_recall", "phase3_f1", "phase4_rank1"):
43         delta = m_p[k] - m_b[k]
44         rows.append({
45             "metric": k,
46             "principal": round(m_p[k], 3),
47             "baseline": round(m_b[k], 3),
48             "delta": round(delta, 3),
49             "magnitude": classify(delta),
50         })
51     pd.DataFrame(rows).to_csv(out_csv, index=False)
52
53 def classify(delta):
54     a = abs(delta)
55     if a < 0.03: return "pequena"
56     if a < 0.10: return "moderada"
57     return "grande"
58
59 if __name__ == "__main__":
60     import sys
61     main(sys.argv[1], sys.argv[2], sys.argv[3])
```